APRENDIZAJE AUTOMÁTICO · PROPUESTA DE PROYECTO

¿Supera el aprendizaje automático al modelo hedónico?

Predicción del precio de vivienda a partir de sus atributos estructurales, frente al modelo hedónico lineal

EQUIPO

Juan Miguel León Gómez · Mauricio José Mozo Terán
Brandon Eduardo Tobar Sánchez

Maestría en Ciencia de Datos e IA
Universidad Autónoma de Occidente

7 de noviembre de 2026

AGENDA

Seis bloques que siguen la guía del curso

1	**Problema y motivación**	Juan Miguel	0:00
2	**Revisión de literatura**	Juan Miguel	3:10
3	**Solución y metodología**	Brandon	4:30
4	**Viabilidad: experimento piloto**	Brandon	7:30
5	**Dataset y análisis exploratorio**	Mauricio	9:00
6	**Plan de trabajo y cierre**	Juan Miguel	13:30

LO QUE PIDE LA GUÍA

1. Introducción y motivación
2. Revisión de literatura
3. Solución con diagrama esquemático
4. Dataset y su visualización

15 min de exposición y 5 de preguntas

PROBLEMA Y MOTIVACIÓN

Valorar viviendas es un problema de alto impacto

Créditos, impuestos y compraventas dependen de un valor estimado.

El avalúo manual es lento, costoso y depende del criterio del perito. Por eso existen los modelos automáticos de valoración, que estiman el precio a partir de los atributos del inmueble.

LO QUE SE NECESITA

Modelos precisos, reproducibles y explicables, elegidos con evidencia.

≈ 50 %
de la riqueza de los hogares
Es su vivienda, en promedio en la OCDE · OCDE (2022)

5,68 %
con catastro al día
Del territorio colombiano en 2019 · CONPES 3958 (DNP)

≈ 9 %
de error en avalúo automático
Comparable al avalúo manual · Kok et al. (2017)

FORMULACIÓN

Regresión supervisada: 12 atributos → precio

5 numéricas — Tamaño del lote, habitaciones, baños, pisos y plazas de garaje

6 binarias — Entrada vehicular, sala de recreación, sótano, calentador a gas, aire central y barrio preferido

1 categórica — Estado de amoblado, con 3 niveles

MODELO

f(x)

aprendido de ventas observadas

SALIDA

Precio

y también log(precio), por su asimetría

545 ventas, sin valores faltantes

13 columnas: 12 atributos y el precio

1987 Windsor (Canadá), vía Kaggle

PREGUNTA DE INVESTIGACIÓN

Una pregunta, cuatro objetivos y tres hipótesis

¿En qué medida los modelos de aprendizaje automático mejoran la predicción del precio de venta de una vivienda frente al modelo hedónico lineal, usando solo atributos estructurales y de localización, y qué atributos explican sus predicciones?

OE1 · DATOS

Caracterizar el dataset

Procedencia, calidad y partición de prueba sellada

OE2 · PREPROCESAMIENTO

Comparar 3 estrategias

Escalado, transformación e ingeniería de variables

OE3 · MODELOS

Comparar 5 o más

CV anidada · RMSE, MAE, MAPE y R^2 · pruebas estadísticas

OE4 · COSTO

Medir y explicar

Tiempos y parámetros · permutación y SHAP

HIPÓTESIS

H1 Al menos un ensamble de árboles logra menor RMSE que el modelo hedónico

H2 Modelar log(precio) reduce el MAPE de los modelos lineales y de distancia

H3 furnishingstatus, añadida en Kaggle, no reduce el RMSE de forma significativa

REVISIÓN DE LITERATURA · PROTOCOLO

De 192 registros a 26 estudios incluidos

11 **fuentes académicas**

IEEE, ScienceDirect, SciELO y otras, con buscador filtrado por dominio

20 **búsquedas con 6 cadenas**

En inglés y en español, con su versión booleana para Scopus y WoS

4 + 7 **criterios explícitos**

De inclusión y de exclusión, aplicados registro por registro



+ 9 por búsqueda de citas = **26 estudios**

Diagrama PRISMA 2020 completo en el anexo

REVISIÓN DE LITERATURA · HALLAZGOS

En Windsor, el hedónico compite con los ensambles

TENDENCIA

Los ensambles de árboles logran la mayor exactitud

Frente al hedónico y frente a otros algoritmos

CONTRAPESO

En Windsor, un paramétrico bien elegido compite

Anglin y Gençay, 1996 · Parmeter et al., 2007 · Haupt et al., 2010

DATOS TABULARES

En tablas medianas, los árboles siguen al frente

Grinsztajn et al., 2022

IMPLICACIÓN PARA EL PROYECTO

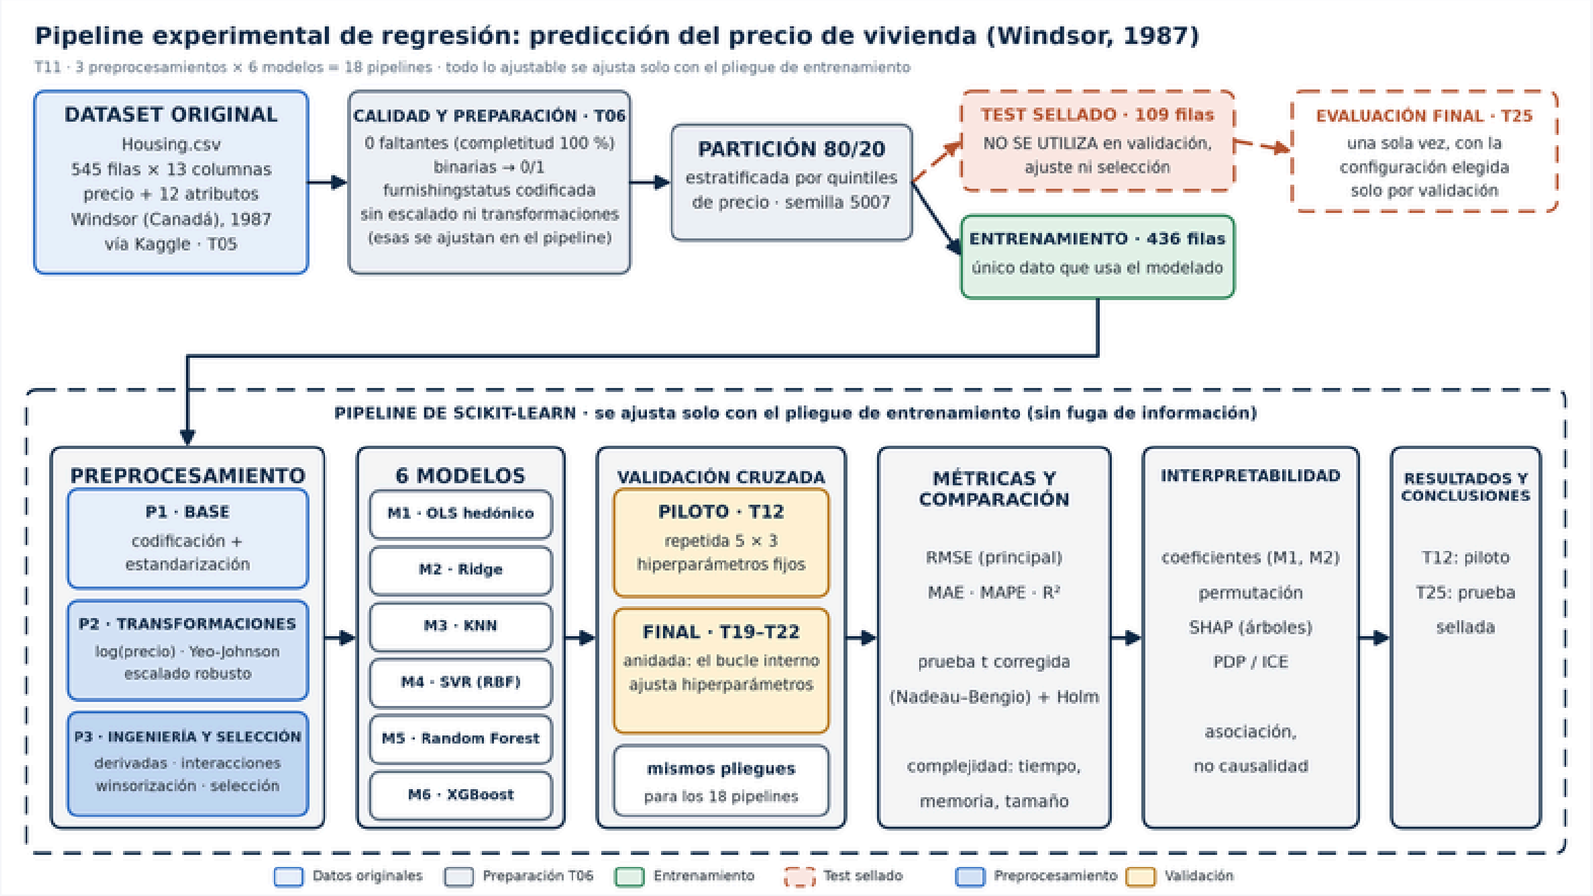
El hedónico es una línea base fuerte: la mejora se compara con pruebas estadísticas, no solo con el error promedio.

ESTUDIOS CLAVE DE LA MATRIZ (26)

- Stang 2022: XGBoost R^2 0,90 frente a OLS 0,87
- Valier 2020: el ML gana 57 de 70 comparaciones
- Čeh 2018: Random Forest supera a la regresión
- Rosso-Mateus 2022: Ridge casi igual a Random Forest

SOLUCIÓN PROPUESTA

La solución: un pipeline de extremo a extremo



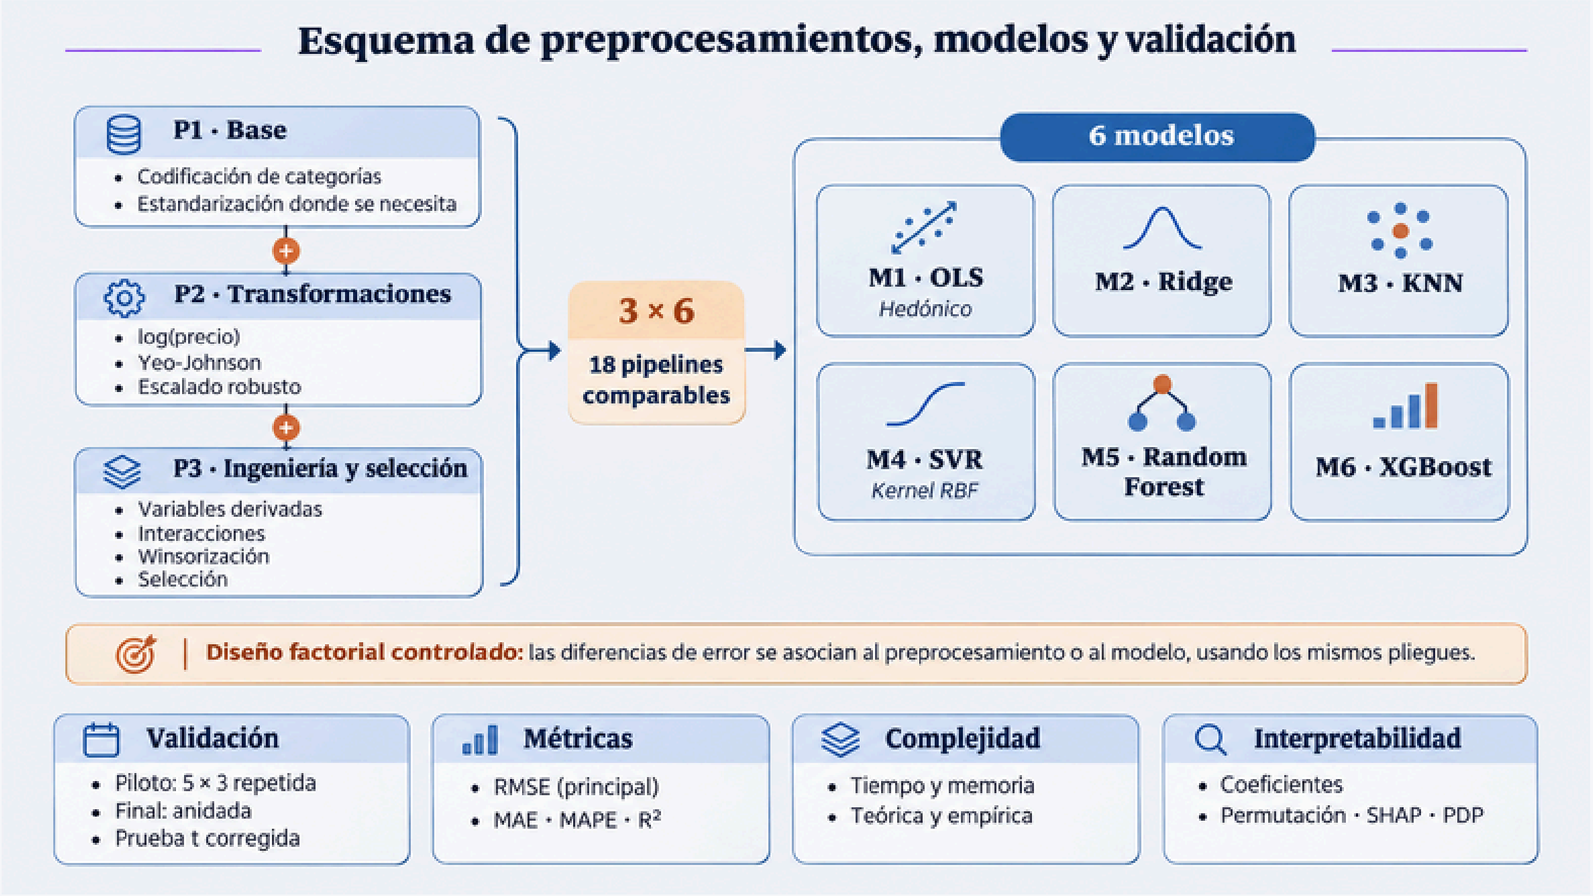
CLAVES DEL DISEÑO

Sin fuga de información

- 436 filas entrenan; 109 quedan selladas hasta el final
- Todo se ajusta dentro de cada pliegue
- 18 pipelines (3 × 6) con los mismos pliegues

METODOLOGÍA

Metodología: 3 preprocesamientos × 6 modelos



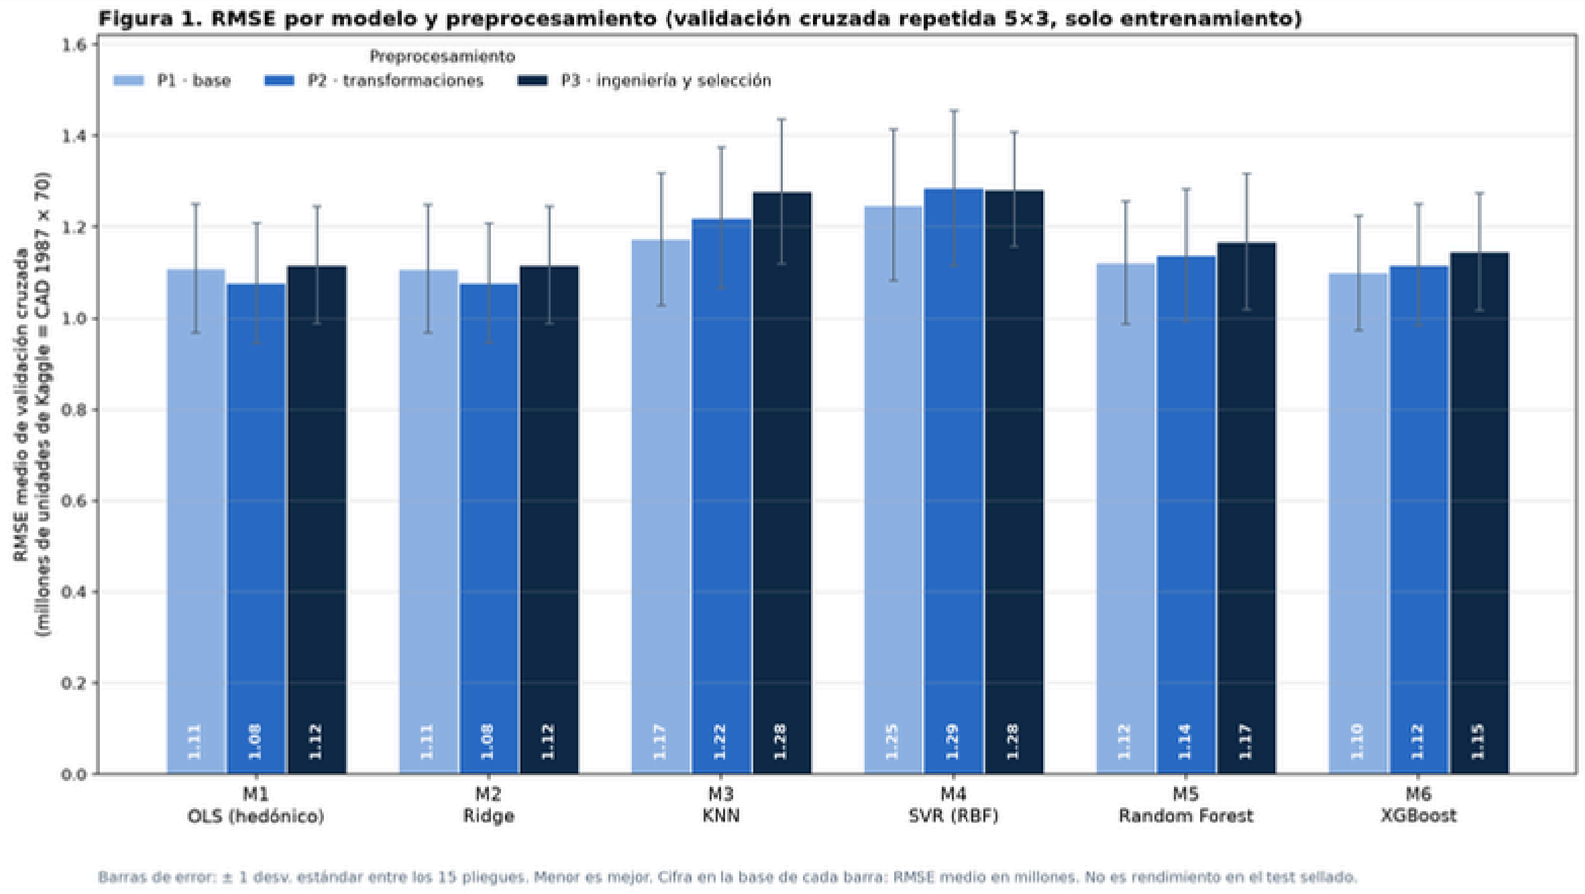
CÓMO COMPARAMOS

Diseño factorial controlado

- Piloto: CV repetida 5 × 3; final: CV anidada
- RMSE como métrica principal, con MAE, MAPE y R^2
- Prueba t corregida para saber si una diferencia es real

VIABILIDAD

Viabilidad: resultados del experimento piloto



LECTURA DEL PILOTO

Viable, sin ganador todavía

- Menor RMSE: Ridge con P2 (R^2 0,66)
- XGBoost queda a 2 % y el OLS hedónico casi igual
- La variación entre pliegues supera esas diferencias
- Hiperparámetros fijos: resultado preliminar

DATASET · ORIGEN

El dataset: origen y variables

(1987) Transacciones Reales (Windsor, Canadá)

(1996) Paper Econométrico · Anglin & Gençay (JAE Data Archive)
- 546 filas × 12 variables (Precios en CAD)
- Traía 1 registro duplicado

(2000) Estandarización en R · Paquete AER (GPL-2/3)
- Dataset 'HousePrices' (Kleiber & Zeileis / Rdatasets)

[Kaggle] Housing Prices Dataset · Yasser H. (CC0: Dominio Público)
- 545 filas × 13 variables
- Modificaciones: Precio × 70, Renombrado de columnas

ESTRUCTURA · 545 × 13

Variables del Modelo

VARIABLE OBJETIVO (TARGET)

price · Precio final de venta

Numérica continua · Rango: [1.75M – 13.30M] (CAD × 70)

12 VARIABLES PREDICTORAS (FEATURES)

DIMENSIONES Y CAPACIDAD (5 NUMÉRICAS)
- **area** · Tamaño del lote en pies² (lotsize)
- **bedrooms / bathrooms** · Habitaciones (1-6) / Baños (1-4)
- **stories / parking** · Pisos sobre rasante (1-4) / Garaje (0-3)

COMODIDADES E INSTALACIONES (5 BINARIAS: YES / NO)
- **mainroad** · Entrada vehicular pavimentada (driveway)
- **guestroom** · Sala de recreación / estar familiar
- **basement** · Sótano completo acondicionado (fullbase)
- **hotwaterheating / aircon** · Calentador gas / Aire central

LOCALIZACIÓN Y ESTADO (2 CATEGÓRICAS)
- **prefarea** · Barrio preferencial de alta cotización (yes / no)
- **furnishingstatus** · Amueblado (furnished / semi / unfurnished)

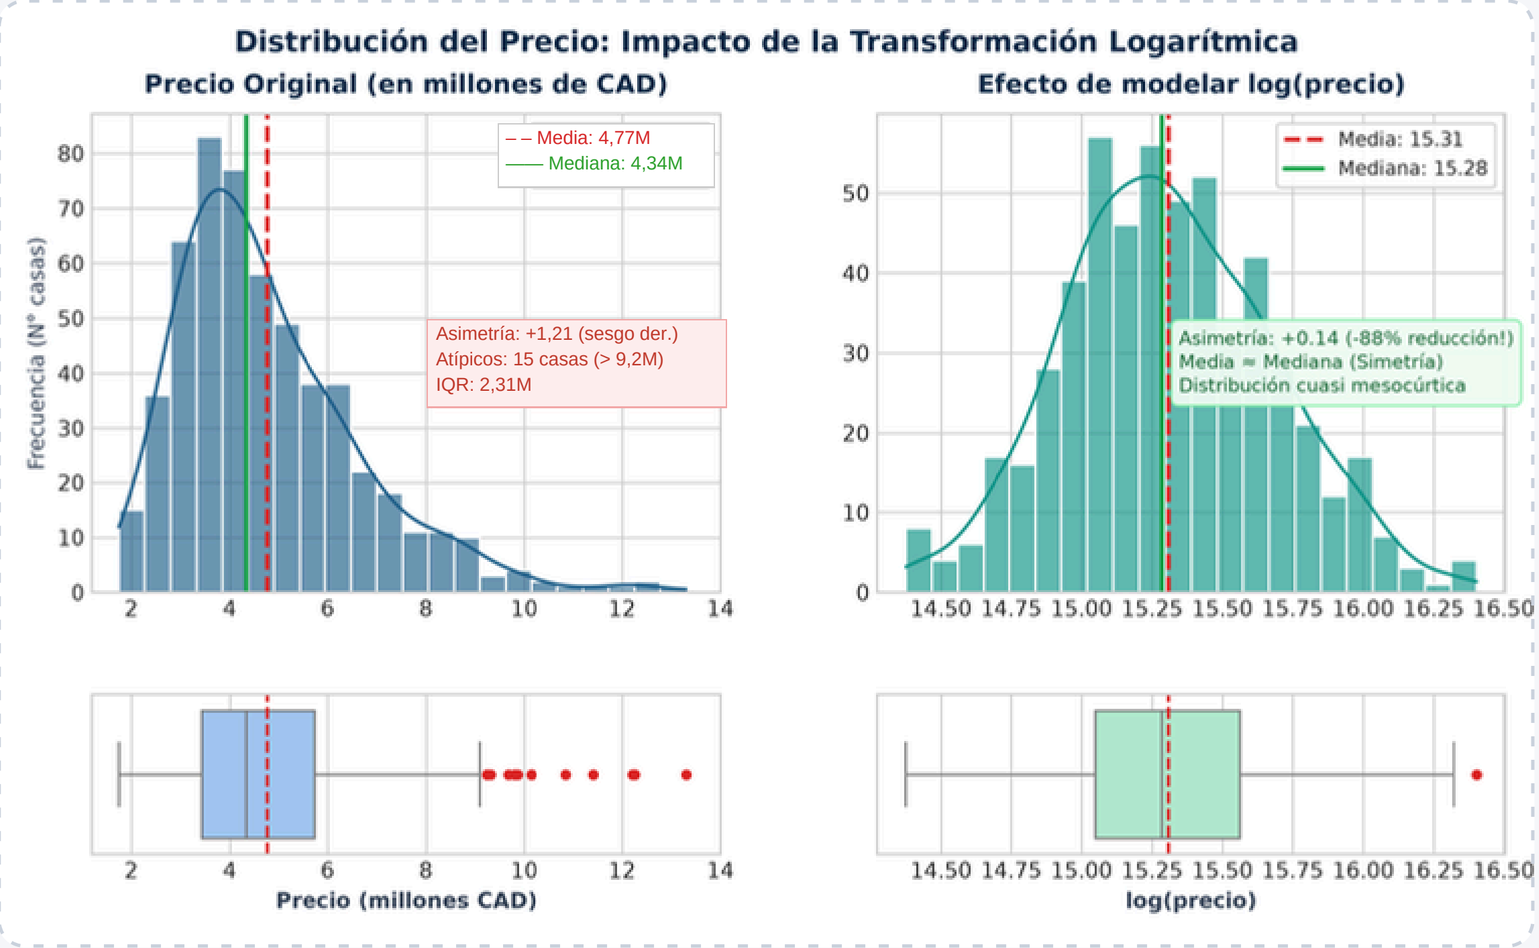
HALLAZGO CLAVE T05:
furnishingstatus no existía en el estudio de Windsor (1987); fue añadida sintéticamente en Kaggle. area es lote, no área construida.

Calidad de los datos y preparación



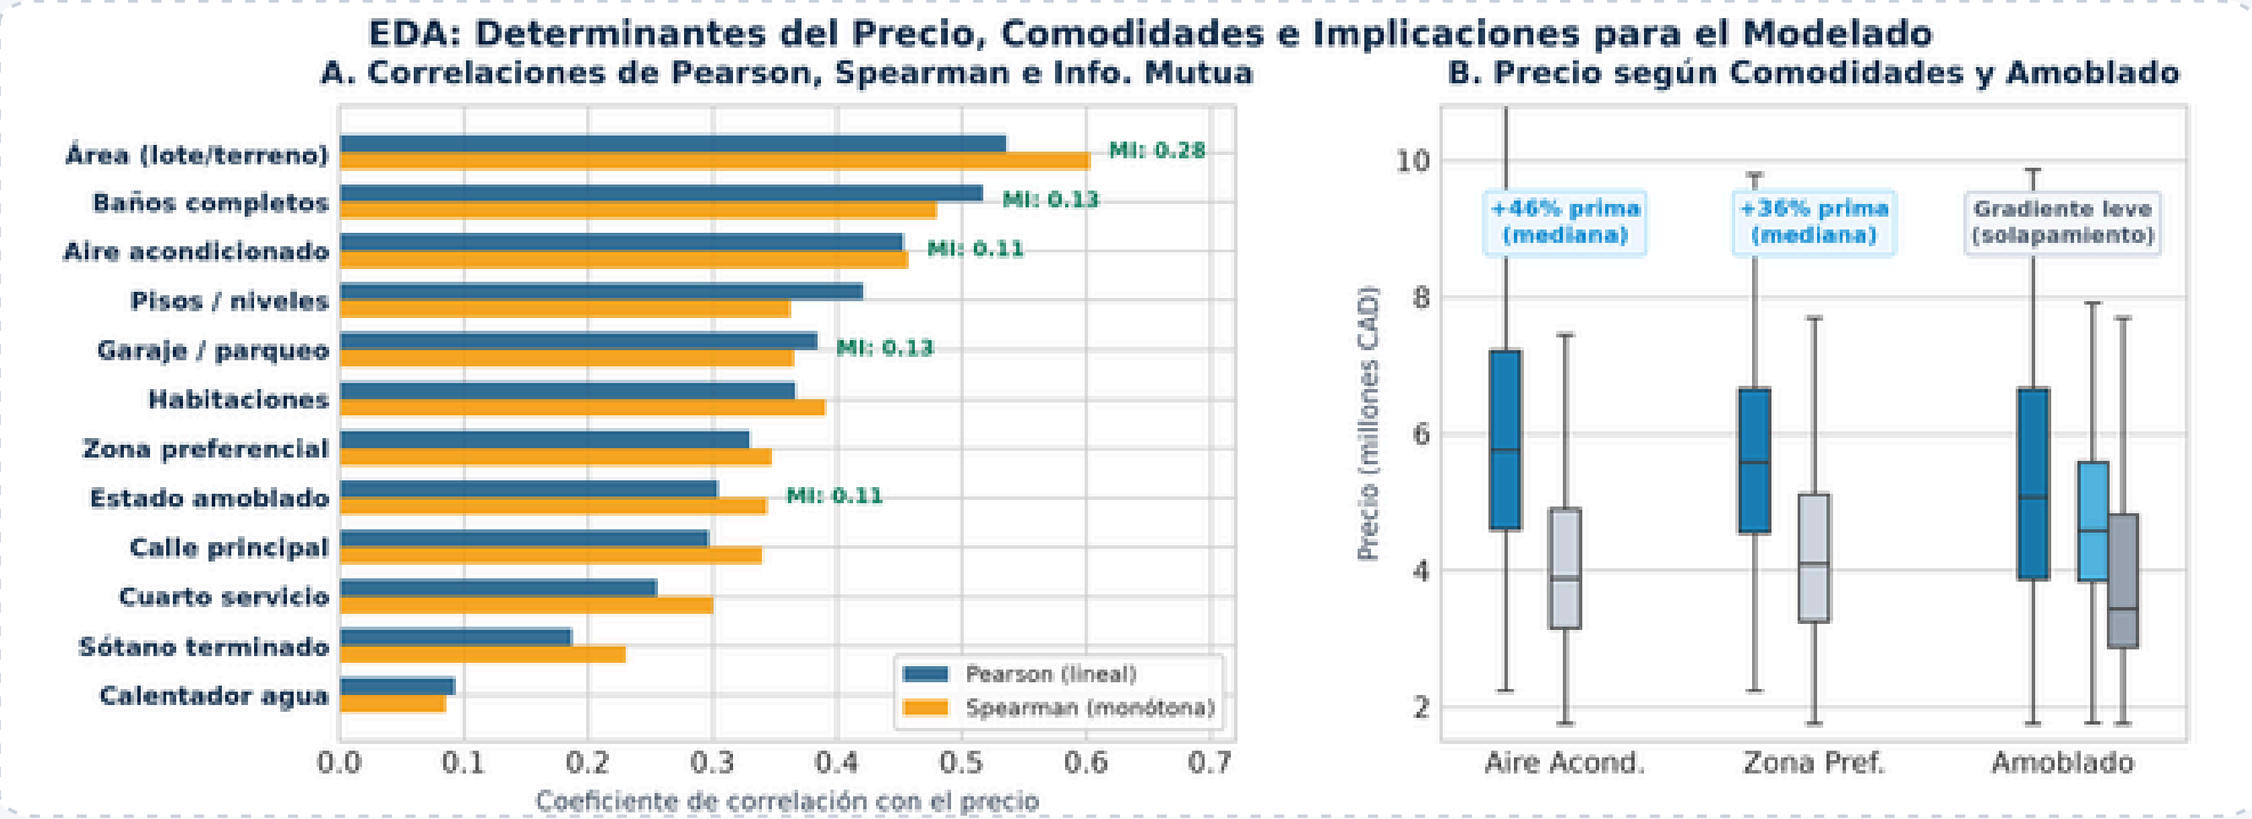
ANÁLISIS EXPLORATORIO

EDA: la distribución del precio



ANÁLISIS EXPLORATORIO

EDA: qué se relaciona con el precio



PLAN DE TRABAJO

Cuatro fases hasta la entrega del 5 de diciembre

4–7 NOV

Propuesta

T01–T15 · en curso

8–21 NOV

Preprocesamiento y modelos

T16–T21

22–29 NOV

Evaluación, complejidad y demo

T22–T26

28 NOV–5 DIC

Paper IEEE y entrega final

T27–T31

Juan Miguel León Gómez	Project Manager y Reporting Lead
Mauricio José Mozo Terán	Data Engineer
Brandon Eduardo Tobar Sánchez	Model Developer y Evaluation Lead

CÓMO TRABAJAMOS

Trello 31 tarjetas con responsable

GitHub una rama y un PR por tarjeta

Colab notebooks sin instalar nada

CIERRE

Una comparación rigurosa, reproducible y explicable

1. Hedónico frente a aprendizaje automático, con datos de origen verificado
2. CV anidada, prueba sellada y pruebas estadísticas: la mejora se demuestra
3. Costo e interpretabilidad medidos, para que el modelo sirva en valoración real

Gracias

¿Preguntas?

Juan Miguel León · Mauricio Mozo · Brandon Tobar
Aprendizaje Automático · UAO

ANEXO

Referencias

[1] S. Rosen, "Hedonic prices and implicit markets: Product differentiation in pure competition," J. Political Economy, vol. 82, no. 1, pp. 34–55, 1974.
[2] P. M. Anglin and R. Gençay, "Semiparametric estimation of a hedonic price function," J. Applied Econometrics, vol. 11, no. 6, pp. 633–648, 1996.
[3] C. F. Parmeter, D. J. Henderson, and S. C. Kumbhakar, "Nonparametric estimation of a hedonic price function," J. Applied Econometrics, vol. 22, no. 3, pp. 695–699, 2007.
[4] H. Haupt, J. Schnurbus, and R. Tschernig, "On nonparametric estimation of a hedonic price function," J. Applied Econometrics, vol. 25, no. 5, pp. 894–901, 2010.
[5] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?," in Proc. NeurIPS, 2022.
[6] OECD, Housing Taxation in OECD Countries, OECD Tax Policy Studies, no. 29. Paris: OECD Publishing, 2022.
[7] N. Kok, E.-L. Koponen, and C. A. Martínez-Barbosa, "Big data in real estate? From manual appraisal to automated valuation," J. Portfolio Management, vol. 43, no. 6, pp. 202–211, 2017.
[8] Departamento Nacional de Planeación, "Estrategia para la implementación de la política pública de catastro multipropósito," Documento CONPES 3958, 2019.
[9] M. J. Page et al., "The PRISMA 2020 statement: An updated guideline for reporting systematic reviews," BMJ, vol. 372, art. n71, 2021.
[10] Yasser H., "Housing Prices Dataset," Kaggle. https://www.kaggle.com/datasets/yasserh/housing-prices-dataset

Las 26 referencias de la revisión sistemática están en docs/entregable_1/02_protocolo_busqueda.md del repositorio.

Diagrama de flujo PRISMA 2020

