APRENDIZAJE AUTOMÁTICO · PROPUESTA DE PROYECTO

# ¿Supera el aprendizaje automático al modelo hedónico?

Predicción del precio de vivienda a partir de sus atributos estructurales, frente al modelo hedónico lineal


EQUIPO

Juan Miguel León Gómez · Mauricio José Mozo Terán
Brandon Eduardo Tobar Sánchez

Maestría en Ciencia de Datos e IA
Universidad Autónoma de Occidente

7 de noviembre de 2026

AGENDA

# Seis bloques que siguen la guía del curso

| | | | |
|---|---|---|---|
| 1 | **Problema y motivación** | Juan Miguel | 0:00 |
| 2 | **Revisión de literatura** | Juan Miguel | 3:10 |
| 3 | **Solución y metodología** | Brandon | 4:30 |
| 4 | **Viabilidad: experimento piloto** | Brandon | 7:30 |
| 5 | **Dataset y análisis exploratorio** | Mauricio | 9:00 |
| 6 | **Plan de trabajo y cierre** | Juan Miguel | 13:30 |

## LO QUE PIDE LA GUÍA

1. Introducción y motivación
2. Revisión de literatura
3. Solución con diagrama esquemático
4. Dataset y su visualización

15 min de exposición y 5 de preguntas

PROBLEMA Y MOTIVACIÓN

# Valorar viviendas es un problema de alto impacto

## Créditos, impuestos y compraventas dependen de un valor estimado.

El avalúo manual es lento, costoso y depende del criterio del perito. Por eso existen los modelos automáticos de valoración, que estiman el precio a partir de los atributos del inmueble.

**LO QUE SE NECESITA**

Modelos precisos, reproducibles y explicables, elegidos con evidencia.

**≈ 50 %**
**de la riqueza de los hogares**
Es su vivienda, en promedio en la OCDE · OCDE (2022)

**5,68 %**
**con catastro al día**
Del territorio colombiano en 2019 · CONPES 3958 (DNP)

**≈ 9 %**
**de error en avalúo automático**
Comparable al avalúo manual · Kok et al. (2017)

FORMULACIÓN

# Regresión supervisada: 12 atributos → precio

**5 numéricas** — Tamaño del lote, habitaciones, baños, pisos y plazas de garaje

**6 binarias** — Entrada vehicular, sala de recreación, sótano, calentador a gas, aire central y barrio preferido

**1 categórica** — Estado de amoblado, con 3 niveles

MODELO

**f(x)**

aprendido de ventas observadas

SALIDA

**Precio**

y también log(precio), por su asimetría

**545** ventas, sin valores faltantes

**13** columnas: 12 atributos y el precio

**1987** Windsor (Canadá), vía Kaggle

PREGUNTA DE INVESTIGACIÓN

# Una pregunta, cuatro objetivos y tres hipótesis

¿En qué medida los modelos de aprendizaje automático mejoran la predicción del precio de venta de una vivienda frente al modelo hedónico lineal, usando solo atributos estructurales y de localización, y qué atributos explican sus predicciones?

OE1 · DATOS

**Caracterizar el dataset**

Procedencia, calidad y partición de prueba sellada

OE2 · PREPROCESAMIENTO

**Comparar 3 estrategias**

Escalado, transformación e ingeniería de variables

OE3 · MODELOS

**Comparar 5 o más**

CV anidada · RMSE, MAE, MAPE y $R^2$ · pruebas estadísticas

OE4 · COSTO

**Medir y explicar**

Tiempos y parámetros · permutación y SHAP

HIPÓTESIS

**H1** Al menos un ensamble de árboles logra menor RMSE que el modelo hedónico

**H2** Modelar log(precio) reduce el MAPE de los modelos lineales y de distancia

**H3** furnishingstatus, añadida en Kaggle, no reduce el RMSE de forma significativa

REVISIÓN DE LITERATURA · PROTOCOLO

# De 192 registros a 26 estudios incluidos

**11** **fuentes académicas**

IEEE, ScienceDirect, SciELO y otras, con buscador filtrado por dominio

**20** **búsquedas con 6 cadenas**

En inglés y en español, con su versión booleana para Scopus y WoS

**4 + 7** **criterios explícitos**

De inclusión y de exclusión, aplicados registro por registro




+ 9 por búsqueda de citas = **26 estudios**

*Diagrama PRISMA 2020 completo en el anexo*

REVISIÓN DE LITERATURA · HALLAZGOS

# En Windsor, el hedónico compite con los ensambles

TENDENCIA

**Los ensambles de árboles logran la mayor exactitud**

Frente al hedónico y frente a otros algoritmos

CONTRAPESO

**En Windsor, un paramétrico bien elegido compite**

Anglin y Gençay, 1996 · Parmeter et al., 2007 · Haupt et al., 2010

DATOS TABULARES

**En tablas medianas, los árboles siguen al frente**

Grinsztajn et al., 2022

IMPLICACIÓN PARA EL PROYECTO

El hedónico es una línea base fuerte: la mejora se compara con pruebas estadísticas, no solo con el error promedio.

PENDIENTE · T10 · BRANDON

Matriz de literatura: 6 a 8 estudios clave con autores, año, datos, mejor modelo y hallazgo, verificados en texto completo.

SOLUCIÓN PROPUESTA

# La solución: un pipeline de extremo a extremo

*Diagrama esquemático del pipeline*

PENDIENTE · T11 · BRANDON

## Lo que lleva esta diapositiva

- Diagrama de extremo a extremo, exportado en PNG
- Datos → calidad → partición sellada → preprocesamiento P1, P2 y P3 → modelos → CV anidada → evaluación → interpretabilidad → demo

**Presenta Brandon · 1:30 (4:30–6:00)**

METODOLOGÍA

# Metodología: 3 preprocesamientos × 6 modelos

*Esquema de preprocesamientos, modelos y validación*

PENDIENTE · T11 · BRANDON

## Lo que lleva esta diapositiva

- P1 base, P2 transformación, P3 ingeniería y selección de variables
- OLS hedónico, regularizados, KNN, SVR, Random Forest y XGBoost
- Prueba sellada del 20 % y CV anidada · RMSE, MAE, MAPE y $R^2$
- Complejidad e interpretabilidad

**Presenta Brandon · 1:30 (6:00–7:30)**

VIABILIDAD

# Viabilidad: resultados del experimento piloto

*Gráfico de RMSE por modelo y preprocesamiento*

PENDIENTE · T12 · BRANDON

## Lo que lleva esta diapositiva

- RMSE (media ± DE) por modelo y preprocesamiento, solo con entrenamiento
- Curva de aprendizaje del mejor modelo lineal y del mejor ensamble
- 3 conclusiones preliminares, sin sobrevender

**Presenta Brandon · 1:30 (7:30–9:00)**

DATASET · ORIGEN

# El dataset: origen y variables

*Cadena de procedencia y diccionario de datos*

PENDIENTE · T05 · MAURICIO

## Lo que lleva esta diapositiva

- Windsor 1987 (Anglin y Gençay) → JAE y AER → Kaggle
- Cambios de Kaggle: precio × 70, una fila duplicada menos y furnishingstatus añadida
- Significado real de cada variable

**Presenta Mauricio · 1:15 (9:00–10:15)**

DATASET · CALIDAD

# Calidad de los datos y preparación

*Tabla resumen de calidad*

PENDIENTE · T06 · MAURICIO

## Lo que lleva esta diapositiva

- Completitud, unicidad, validez, atípicos y desbalance
- El archivo viene ordenado por precio: se baraja antes de partir
- Partición sellada 80/20 estratificada, semilla 5007

**Presenta Mauricio · 1:00 (10:15–11:15)**

ANÁLISIS EXPLORATORIO

# EDA: la distribución del precio

*Histograma y boxplot del precio*

PENDIENTE · T07 · MAURICIO

## Lo que lleva esta diapositiva

- Histograma y boxplot del precio
- Efecto de modelar log(precio)
- Media, mediana, asimetría y atípicos

**Presenta Mauricio · 1:10 (11:15–12:25)**

ANÁLISIS EXPLORATORIO

# EDA: qué se relaciona con el precio

*Correlaciones y comparaciones por grupo*

PENDIENTE · T07 · MAURICIO

## Lo que lleva esta diapositiva

- Correlaciones de Pearson y Spearman e información mutua
- Precio por comodidades y por estado de amoblado
- Implicaciones para el modelado

**Presenta Mauricio · 1:05 (12:25–13:30)**

PLAN DE TRABAJO

# Cuatro fases hasta la entrega del 5 de diciembre

**4–7 NOV**

**Propuesta**

T01–T15 · en curso

**8–21 NOV**

**Preprocesamiento y modelos**

T16–T21

**22–29 NOV**

**Evaluación, complejidad y demo**

T22–T26

**28 NOV–5 DIC**

**Paper IEEE y entrega final**

T27–T31

| | |
|---|---|
| **Juan Miguel León Gómez** | Project Manager y Reporting Lead |
| **Mauricio José Mozo Terán** | Data Engineer |
| **Brandon Eduardo Tobar Sánchez** | Model Developer y Evaluation Lead |

**CÓMO TRABAJAMOS**

**Trello** 31 tarjetas con responsable

**GitHub** una rama y un PR por tarjeta

**Colab** notebooks sin instalar nada

CIERRE

# Una comparación rigurosa, reproducible y explicable

1. Hedónico frente a aprendizaje automático, con datos de origen verificado
2. CV anidada, prueba sellada y pruebas estadísticas: la mejora se demuestra
3. Costo e interpretabilidad medidos, para que el modelo sirva en valoración real

## Gracias

¿Preguntas?

Juan Miguel León · Mauricio Mozo · Brandon Tobar
Aprendizaje Automático · UAO

ANEXO

# Referencias


[1] S. Rosen, "Hedonic prices and implicit markets: Product differentiation in pure competition," J. Political Economy, vol. 82, no. 1, pp. 34–55, 1974.
[2] P. M. Anglin and R. Gençay, "Semiparametric estimation of a hedonic price function," J. Applied Econometrics, vol. 11, no. 6, pp. 633–648, 1996.
[3] C. F. Parmeter, D. J. Henderson, and S. C. Kumbhakar, "Nonparametric estimation of a hedonic price function," J. Applied Econometrics, vol. 22, no. 3, pp. 695–699, 2007.
[4] H. Haupt, J. Schnurbus, and R. Tschernig, "On nonparametric estimation of a hedonic price function," J. Applied Econometrics, vol. 25, no. 5, pp. 894–901, 2010.
[5] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?," in Proc. NeurIPS, 2022.
[6] OECD, Housing Taxation in OECD Countries, OECD Tax Policy Studies, no. 29. Paris: OECD Publishing, 2022.
[7] N. Kok, E.-L. Koponen, and C. A. Martínez-Barbosa, "Big data in real estate? From manual appraisal to automated valuation," J. Portfolio Management, vol. 43, no. 6, pp. 202–211, 2017.
[8] Departamento Nacional de Planeación, "Estrategia para la implementación de la política pública de catastro multipropósito," Documento CONPES 3958, 2019.
[9] M. J. Page et al., "The PRISMA 2020 statement: An updated guideline for reporting systematic reviews," BMJ, vol. 372, art. n71, 2021.
[10] Yasser H., "Housing Prices Dataset," Kaggle. https://www.kaggle.com/datasets/yasserh/housing-prices-dataset


*Las 26 referencias de la revisión sistemática están en docs/entregable_1/02_protocolo_busqueda.md del repositorio.*

# Diagrama de flujo PRISMA 2020

