¿Supera el aprendizaje automático al modelo hedónico?



Predicción del precio de vivienda a partir de sus atributos estructurales · Propuesta de proyecto

Juan Miguel León Gómez · Mauricio José Mozo Terán · Brandon Eduardo Tobar Sánchez

Aprendizaje Automático · Maestría en Ciencia de Datos e Inteligencia Artificial · Universidad Autónoma de Occidente · 7 de noviembre de 2026

Agenda y responsables

1

Problema y motivación
Juan Miguel
desde 0:00

2

Revisión de literatura
Juan Miguel
desde 3:10

3

Solución y metodología
Brandon
desde 4:30

4

Viabilidad: piloto
Brandon
desde 7:30

5

Dataset y EDA
Mauricio
desde 9:00

6

Plan y cierre
Juan Miguel
desde 13:30

Exposición de 15 min + 5 min de preguntas. Cada sección corresponde a una tarjeta del tablero del equipo y a un Pull Request en el repositorio.

Valorar viviendas es un problema de alto impacto

≈ 50 %

de la riqueza bruta de los hogares en la OCDE es su vivienda

OCDE (2022)

5,68 %

del territorio colombiano tenía catastro actualizado en 2019

CONPES 3958 (DNP, 2019)

≈ 9 %

de error absoluto de un modelo automático de valoración, comparable al avalúo manual

Kok et al. (2017)

Créditos, impuestos y compraventas dependen de un valor estimado: se necesitan modelos precisos, reproducibles y explicables.

Regresión supervisada: 12 atributos → precio

5 numéricas — Tamaño del lote, habitaciones, baños, pisos, plazas de garaje

6 binarias — Entrada vehicular, sala de recreación, sótano, calentador a gas, aire central, barrio preferido

1 categórica — Estado de amoblado (3 niveles)



545 ventas · 13 columnas · sin faltantes
Windsor (Canadá), 1987, vía Kaggle.
No es un dataset incluido en scikit-learn.

Pregunta, objetivos e hipótesis

¿En qué medida los modelos de aprendizaje automático mejoran la predicción del precio frente al modelo hedónico lineal, y qué atributos explican sus predicciones?

OE1

Caracterizar los datos
Procedencia, calidad y partición de prueba sellada

OE2

Comparar 3 preprocesamientos
Codificación, transformación e ingeniería de variables

OE3

Ajustar 5+ modelos
CV anidada, RMSE, MAE, MAPE, R^2 y pruebas estadísticas

OE4

Medir costo y explicar
Complejidad teórica y empírica; SHAP

H1

Un ensamble de árboles logra menor RMSE que el modelo hedónico.

H2

Modelar log(precio) reduce el MAPE de los modelos lineales y de distancia.

H3

furnishingstatus (añadida en Kaggle) no reduce el RMSE de forma significativa.

Búsqueda sistemática: de 192 registros a 26 estudios

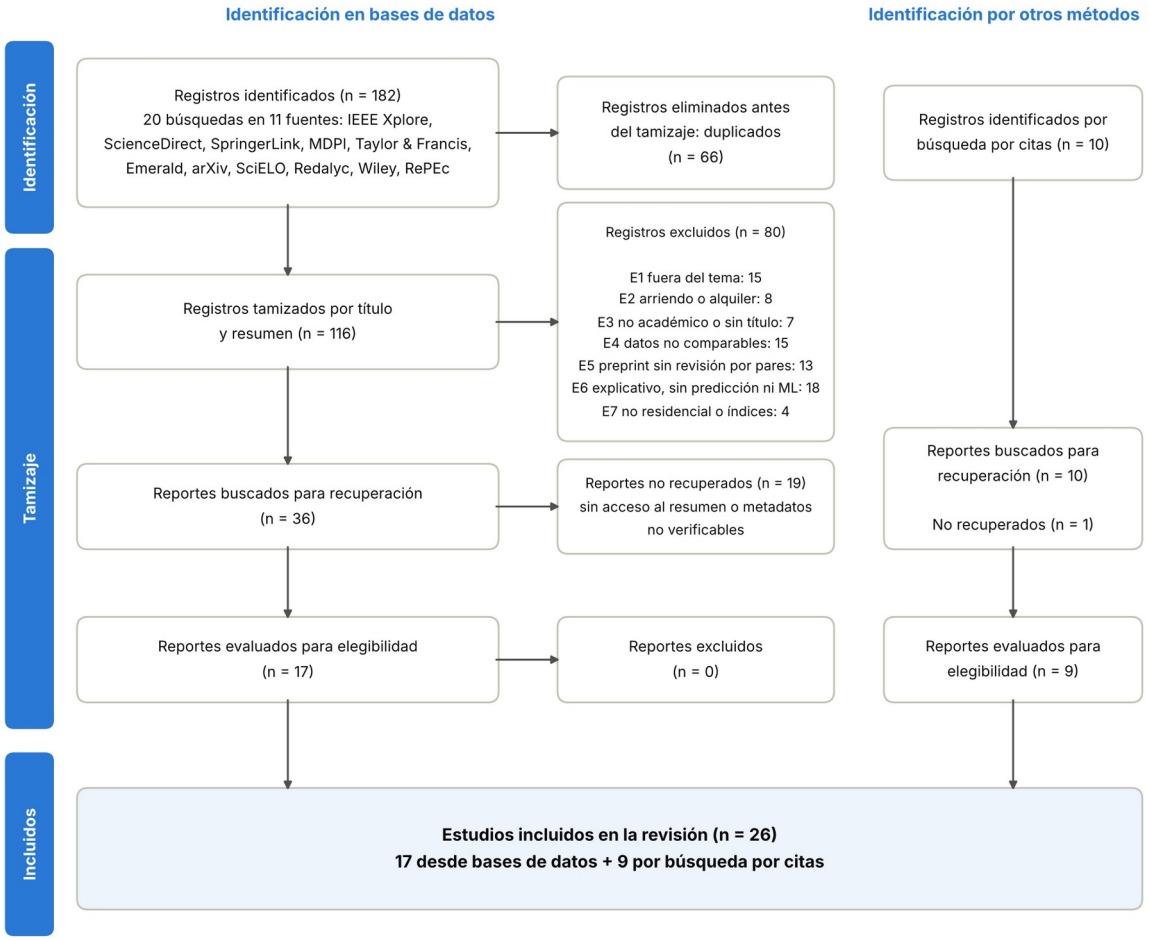
11 fuentes académicas
IEEE Xplore, ScienceDirect, SpringerLink, MDPI, Taylor & Francis, Emerald, Wiley, arXiv, RePEc, SciELO y Redalyc

6 cadenas, 20 búsquedas
En inglés y español, con su equivalente booleano para Scopus y Web of Science

Criterios explícitos
4 de inclusión y 7 de exclusión, aplicados registro por registro

Registro reproducible
Excel con tamizaje y conteos PRISMA, y scripts en el repositorio

Diagrama de flujo PRISMA 2020 · Revisión de literatura (búsqueda del 4 de noviembre de 2026)



Fuente: docs/entregable_1/registro_busquedas.xlsx (hoja PRISMA). Formato: Page et al., PRISMA 2020.

Lo que dice la literatura

PENDIENTE · T10 · Brandon

Presenta: Juan Miguel · Tiempo: 0:40 (3:50–4:30)

Contenido que el responsable incorpora con el PR de su tarjeta:

- Tabla corta con 6–8 estudios clave: autores, año, datos, mejor modelo y hallazgo
- Síntesis en 3–4 mensajes por pregunta de revisión (RQ1–RQ4)
- Brecha que justifica la propuesta: comparación rigurosa ML vs hedónico sobre los datos de Windsor
- Fuente: hoja Incluidos de registro_busquedas.xlsx y sección 2.8 del protocolo

Solución propuesta: el pipeline de extremo a extremo

PENDIENTE · T11 · Brandon

Presenta: Brandon · Tiempo: 1:30 (4:30–6:00)

Contenido que el responsable incorpora con el PR de su tarjeta:

- Diagrama esquemático (draw.io exportado a PNG) que ocupe la diapositiva
- Etapas: datos → calidad → partición sellada → preprocesamiento P1/P2/P3 → modelos → CV anidada → evaluación → interpretabilidad → demo

Metodología: 3 preprocesamientos × 6 modelos

PENDIENTE · T11 · Brandon

Presenta: Brandon · Tiempo: 1:30 (6:00–7:30)

Contenido que el responsable incorpora con el PR de su tarjeta:

- P1 base, P2 transformación, P3 ingeniería y selección de variables
- Modelos: OLS hedónico, Ridge/Lasso/ElasticNet, KNN, SVR, Random Forest, XGBoost
- Validación: prueba sellada 20 % + CV 5×5 anidada; RMSE, MAE, MAPE, R^2; prueba estadística
- Análisis de complejidad (O(·), tiempos, parámetros) e interpretabilidad (SHAP)

Viabilidad: resultados del experimento piloto

PENDIENTE · T12 · Brandon

Presenta: Brandon · Tiempo: 1:30 (7:30–9:00)

Contenido que el responsable incorpora con el PR de su tarjeta:

- Gráfico comparativo de RMSE (media ± DE) por modelo y preprocesamiento, solo en entrenamiento
- Curva de aprendizaje del mejor modelo lineal y del mejor ensamble
- 3 conclusiones preliminares, sin sobrevender

El dataset: origen y variables

PENDIENTE · T05 · Mauricio

Presenta: Mauricio · Tiempo: 1:15 (9:00–10:15)

Contenido que el responsable incorpora con el PR de su tarjeta:

- Cadena de procedencia: Windsor 1987 (Anglin y Gençay) → JAE/AER → Kaggle
- Transformaciones de Kaggle: precio × 70, fila duplicada eliminada, furnishingstatus añadida
- Diccionario: significado real de cada variable (p. ej., area = tamaño del lote; mainroad = entrada vehicular)

Calidad de los datos y preparación

PENDIENTE · T06 · Mauricio

Presenta: Mauricio · Tiempo: 1:00 (10:15–11:15)

Contenido que el responsable incorpora con el PR de su tarjeta:

- Tabla resumen de calidad: completitud, unicidad, validez, atípicos, desbalance
- Artefacto de orden (CSV ordenado por precio) y cómo se corrige
- Partición sellada 80/20 estratificada, semilla 5007

EDA: el precio es asimétrico

PENDIENTE · T07 · Mauricio

Presenta: Mauricio · Tiempo: 1:10 (11:15–12:25)

Contenido que el responsable incorpora con el PR de su tarjeta:

- Histograma + boxplot del precio y efecto de log(precio)
- Estadísticos clave: media, mediana, asimetría, curtosis, atípicos

EDA: qué se relaciona con el precio

PENDIENTE · T07 · Mauricio

Presenta: Mauricio · Tiempo: 1:05 (12:25–13:30)

Contenido que el responsable incorpora con el PR de su tarjeta:

- Correlaciones de Pearson y Spearman e información mutua con el precio
- Precio por comodidades binarias y por estado de amoblado
- Implicaciones para el modelado

Plan de trabajo, roles y herramientas

4–7 nov
Propuesta
T01–T15

8–21 nov
Preprocesamiento y modelos
T16–T21

22–29 nov
Evaluación, complejidad y demo
T22–T26

28 nov–5 dic
Paper IEEE y entrega final
T27–T31

Juan Miguel León Gómez
Project Manager · Reporting Lead

Mauricio José Mozo Terán
Data Engineer

Brandon Eduardo Tobar Sánchez
Model Developer · Evaluation Lead

Trello: 31 tarjetas con responsable, fecha y criterios de aceptación

GitHub: una rama y un Pull Request por tarjeta

Colab: notebooks ejecutables sin instalar nada

Entrega final estimada: 5 de diciembre · paper IEEE en inglés, código reproducible y demo de 20 min

Una comparación rigurosa, reproducible y explicable

1. Comparamos el modelo hedónico clásico con aprendizaje automático sobre un dataset de referencia con origen verificado

2. Validación cruzada anidada, prueba sellada y pruebas estadísticas: la mejora se demuestra, no se supone

3. Medimos costo e interpretabilidad para que el modelo pueda usarse en valoración real

¿Preguntas?

Referencias

[1] S. Rosen, "Hedonic prices and implicit markets: Product differentiation in pure competition," J. Political Economy, vol. 82, no. 1, pp. 34–55, 1974.

[2] P. M. Anglin and R. Gençay, "Semiparametric estimation of a hedonic price function," J. Applied Econometrics, vol. 11, no. 6, pp. 633–648, 1996.

[3] OECD, Housing Taxation in OECD Countries, OECD Tax Policy Studies, no. 29. Paris: OECD Publishing, 2022, doi: 10.1787/03dfe007-en.

[4] IAAO, Standard on Automated Valuation Models (AVMs). Kansas City, MO: IAAO, 2018.

[5] N. Kok, E.-L. Koponen, and C. A. Martínez-Barbosa, "Big data in real estate? From manual appraisal to automated valuation," J. Portfolio Management, vol. 43, no. 6, pp. 202–211, 2017.

[6] Departamento Nacional de Planeación, "Estrategia para la implementación de la política pública de catastro multipropósito," Documento CONPES 3958, 2019.

[7] M. J. Page et al., "The PRISMA 2020 statement: An updated guideline for reporting systematic reviews," BMJ, vol. 372, art. n71, 2021.

[8] Yasser H., "Housing Prices Dataset," Kaggle. https://www.kaggle.com/datasets/yasserh/housing-prices-dataset

Las 26 referencias de la revisión de literatura están en docs/entregable_1/02_protocolo_busqueda.md.