APRENDIZAJE AUTOMÁTICO · ENTREGABLE 1

Revisión de literatura: predicción del precio de vivienda con aprendizaje automático frente al modelo hedónico

Protocolo de búsqueda sistemática, estudios incluidos y síntesis de hallazgos

Juan Miguel León Gómez · Brandon Eduardo Tobar Sánchez · Mauricio José Mozo Terán

Maestría en Ciencia de Datos e Inteligencia Artificial

Universidad Autónoma de Occidente · Noviembre de 2026

1. Objetivo y preguntas de revisión

La revisión identifica las soluciones publicadas al problema de estimar el precio de venta de viviendas, con modelos hedónicos y de aprendizaje automático, para fundamentar el diseño metodológico del proyecto. Se guía por cuatro preguntas (tabla 1).

Tabla 1. Preguntas de revisión

Código	Pregunta de revisión
RQ1	¿Qué métodos de aprendizaje automático se usan para predecir precios de vivienda y cómo se comparan con la regresión hedónica?
RQ2	¿Qué estrategias de preprocesamiento e ingeniería de variables se emplean?
RQ3	¿Qué esquemas de validación y métricas de desempeño se reportan?
RQ4	¿Qué técnicas de interpretabilidad se aplican a los modelos?

2. Protocolo de búsqueda

La búsqueda se ejecutó el 4 de noviembre de 2026 y se reporta según la guía PRISMA 2020 [27]. El registro completo (búsquedas, registros, tamizaje, estudios incluidos y conteos) está en el archivo registro_busquedas.xlsx del repositorio del proyecto.

2.1 Fuentes de información

La búsqueda cubrió 11 fuentes académicas:

- Editoriales con revisión por pares: IEEE Xplore, ScienceDirect (Elsevier), SpringerLink, MDPI, Taylor & Francis, Emerald y Wiley Online Library.
- Repositorios: arXiv y RePEc (IDEAS/EconPapers).
- Índices latinoamericanos: SciELO y Redalyc.

Las bases no se consultaron desde su propio buscador ni desde Scopus o Web of Science. Cada búsqueda se hizo en un motor de búsqueda web restringido al dominio de la base (operador site:), así que los conteos son los resultados que devolvió el motor para ese dominio, no el total de registros de la base.

La búsqueda se complementó con búsqueda por citas, hacia atrás y hacia adelante, desde los estudios recuperados, en particular desde las réplicas publicadas en el *Journal of Applied Econometrics* sobre los datos de Windsor.

2.2 Estrategia de búsqueda

Cada cadena se ejecutó en un motor de búsqueda web con filtro por dominio, una vez por base, sin usar los buscadores internos de las bases ni sus filtros. Se registraron los primeros resultados por relevancia (hasta 10 por búsqueda) con título, URL y posición. Cada cadena tiene su equivalente booleano para replicarla en Scopus o Web of Science (tabla 2).

Tabla 2. Cadenas de búsqueda

Cadena	Texto ejecutado	Equivalente booleano
C1	house price prediction machine learning random forest gradient boosting XGBoost	("house price*" OR "housing price*") AND ("machine learning" OR "random forest" OR "gradient boosting" OR XGBoost)
C2	hedonic pricing model versus machine learning house prices comparison	hedonic AND "machine learning" AND ("house price*" OR housing) AND (compar* OR versus)
C3	automated valuation model mass appraisal machine learning residential property	("automated valuation model*" OR AVM OR "mass appraisal") AND "machine learning" AND residential
C4	explainable machine learning SHAP house price prediction interpretability	(explainab* OR interpretab* OR SHAP) AND "machine learning" AND ("house price*" OR "property valuation")
C5	predicción precio vivienda aprendizaje automático modelos regresión	("precio* de vivienda" OR avalúo) AND ("aprendizaje automático" OR "machine learning" OR regresión)
C6	Windsor house prices Anglin Gencay hedonic semiparametric nonparametric estimation replication	(Windsor OR "Anglin and Gencay") AND hedonic AND (semiparametric OR nonparametric)

Tabla 3. Búsquedas ejecutadas y resultados registrados

ID	Cadena	Base de datos	Resultados
B01	C1	IEEE Xplore	9
B02	C1	ScienceDirect	9
B03	C1	SpringerLink	9
B04	C1	MDPI	9
B05	C1	arXiv	9
B06	C2	ScienceDirect	9
B07	C2	SpringerLink	9
B08	C2	MDPI	9
B09	C2	Taylor & Francis	9
B10	C3	ScienceDirect	9
B11	C3	MDPI	9
B12	C3	Taylor & Francis	9
B13	C3	Emerald	9
B14	C4	IEEE Xplore	9
B15	C4	ScienceDirect	9
B16	C4	MDPI	9
B17	C5	SciELO	9
B18	C5	Redalyc	9
B19	C6	Wiley Online Library	10
B20	C6	RePEc (IDEAS/EconPapers)	10

2.3 Criterios de elegibilidad

Criterios de inclusión

- **I1:** estudia la estimación o predicción del precio de inmuebles residenciales, o usa los datos de Windsor (Anglin y Gençay, 1996).
- **I2:** aplica o compara modelos de aprendizaje automático y/o hedónicos, o aporta metodología directamente aplicable (métricas, selección de variables, interpretabilidad).
- **I3:** es una publicación académica con metadatos verificables (autores, año, fuente, DOI o URL del editor).
- **I4:** está en inglés o español.

Criterios de exclusión

- **E1:** Fuera del tema (no trata la valoración de vivienda).
- **E2:** Precio de arriendo o alquiler de corto plazo, no precio de venta.
- **E3:** No es un documento académico identificable (patente, perfil o registro sin título).
- **E4:** Depende de datos no comparables con el proyecto (imágenes, coordenadas, redes espaciales o fuentes múltiples).
- **E5:** Preprint sin evidencia de revisión por pares.
- **E6:** Objetivo explicativo o causal, sin componente predictivo ni de aprendizaje automático.
- **E7:** No residencial (comercial o suelo) o construcción de índices de precios.

2.4 Proceso de selección

1. **Eliminación de duplicados:** por título normalizado (sin tildes, mayúsculas ni signos). Además se eliminó una publicación indexada en dos idiomas.
2. **Tamizaje** por título y resumen con los criterios E1–E7.
3. **Recuperación y verificación (evaluación por resumen):** de cada registro que pasó el tamizaje se verificaron los metadatos (autores, año, revista, volumen y DOI o URL del editor) en la página del editor y se leyó el resumen. La elegibilidad se decidió con el resumen y esos metadatos; en esta etapa no se leyó el texto completo. Los registros sin acceso al resumen o con metadatos no verificables se marcaron como *no recuperados*.
4. **Búsqueda por citas** desde los estudios verificados, con el mismo procedimiento de verificación.
5. **Lectura del texto completo:** la hace T10 al llenar la matriz. Si un estudio no cumple los criterios al leerlo completo, se excluye y se actualizan los conteos.

2.5 Resultados de la búsqueda

De 192 registros identificados (182 en bases de datos y 10 por citas) se incluyeron 26 estudios publicados entre 1974 y 2025, 20 de ellos desde 2015. La figura 1 muestra el flujo completo y la tabla 4, los conteos por etapa.

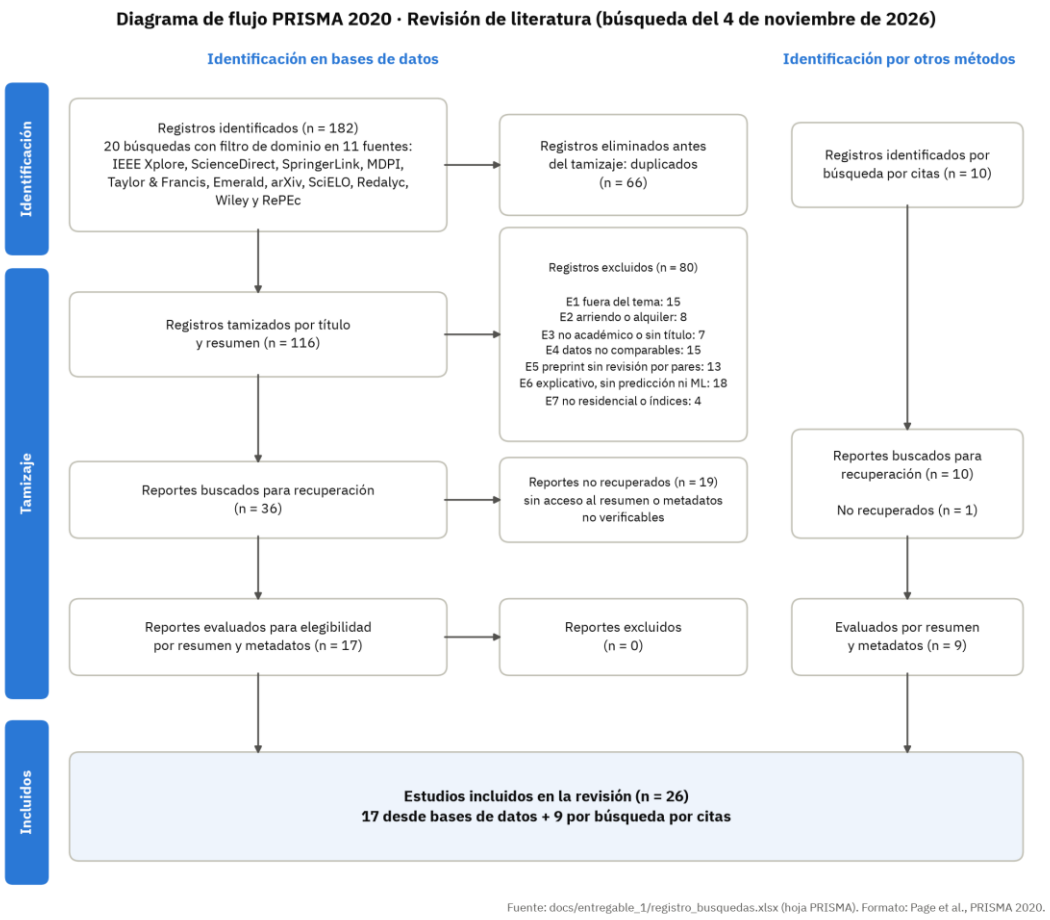


Figura 1. Diagrama de flujo PRISMA 2020 de la búsqueda

Tabla 4. Conteos por etapa

Etapa	n
Registros identificados en bases de datos	**182**
Registros identificados por búsqueda por citas	**10**
Duplicados eliminados antes del tamizaje	**66**
Registros tamizados (título y resumen)	**116**
Registros excluidos en el tamizaje	**80**
Reportes buscados para recuperación (bases de datos)	**36**
Reportes no recuperados (bases de datos)	**19**
Reportes evaluados para elegibilidad (bases de datos)	**17**
Reportes no recuperados (búsqueda por citas)	**1**
Reportes evaluados (búsqueda por citas)	**9**
Total de estudios incluidos en la revisión	**26**

En la figura 1 y la tabla 4, la elegibilidad se evaluó con el resumen y los metadatos verificados en la página del editor, no con el texto completo. La lectura completa de cada estudio se hace al construir la matriz de la sección 3.

3. Estudios incluidos y principales hallazgos

La tabla 5 agrupa los 26 estudios incluidos por categoría. La tabla 6 resume cada uno con sus datos, modelos, hallazgo, resultado verificable y nivel de verificación; la tabla 7 reúne preprocesamiento, validación y métricas; y la tabla 8 documenta la verificación de los identificadores. La matriz completa, con todas las columnas, está en matriz_literatura.xlsx y en la hoja Matriz_T10 de registro_busquedas.xlsx. El identificador Exx corresponde a la referencia [xx].

Tabla 5. Composición de los estudios incluidos por categoría

Categoría	Estudios
ML vs hedónico	9 (E05, E06, E07, E10, E13, E14, E18, E19, E21)
Dataset Windsor	3 (E02, E03, E04)
AVM	3 (E08, E20, E22)
Interpretabilidad	3 (E11, E15, E23)
Metodológico	2 (E09, E26)
Latinoamérica	2 (E24, E25)
Fundamento teórico	1 (E01)
Revisión	1 (E12)
Métricas	1 (E16)
Preprocesamiento	1 (E17)

Nivel de verificación (T10, 5–6 nov. 2026): texto completo, 2 estudios (E20, E26); solo resumen, 21; solo metadatos, 3 (E01, E15, E19). "n. r." significa no reportado en lo leído: el dato no apareció en el texto al que se tuvo acceso. Los hallazgos de T09 no verificados se señalan como tales.

Tabla 6. Matriz de estudios incluidos

ID	Estudio	País y datos (n)	Modelos	Hallazgo y resultado verificable	Nivel	RQ
E01	Rosen (1974)	Teórico (sin datos)	Teoría de precios hedónicos (equilibrio en el espacio de atributos)	Base teórica: el precio de un bien diferenciado es función de sus atributos y cada atributo tiene un precio implícito.	Solo metadatos	RQ1
E02	Anglin y Gençay (1996)	Resumen no menciona dataset ni n (Windsor, 546 ventas y jul–sep 1987 vienen de T09 y no se reverificaron aquí)	Modelo paramétrico de referencia (Box-Cox) vs modelo semiparamétrico	El enfoque semiparamétrico mejora la predicción media frente al paramétrico estándar, que sí pasa las pruebas de especificación usuales. Resultado: El semiparamétrico da predicciones medias más precisas que el paramétrico de referencia (sin cifras leídas).	Solo resumen	RQ1, RQ2
E03	Parmeter et al. (2007)	Réplica de un modelo parcialmente lineal; el resumen no nombra Windsor	Regresión kernel no paramétrica con suavizado de variables categóricas	Replica el modelo parcialmente lineal previo con un enfoque no paramétrico (según el resumen).	Solo resumen	RQ1, RQ2
E04	Haupt et al. (2010)	Datos de vivienda canadienses (resumen); n NR	Especificación paramétrica previa vs métodos no paramétricos	Una especificación paramétrica bien elegida no tiene por qué rechazarse; los métodos no paramétricos aportan en cada etapa del modelado. Resultado: No se rechaza la especificación paramétrica previamente propuesta (sin cifras).	Solo resumen	RQ1
E05	Selim (2009)	Turquía, Encuesta de Presupuesto de los Hogares 2004 (resumen); n NR	Regresión hedónica vs red neuronal artificial (ANN)	Compara hedónico y ANN; la ANN predice mejor. La lista de atributos clave de T09 no se verificó. Resultado: La ANN resulta la mejor alternativa predictiva frente a la hedónica (sin cifras leídas).	Solo resumen	RQ1
E06	Antipov y Pokryshevskaya (2012)	El resumen no confirma país ni n (T09: apartamentos de Rusia)	Random Forest vs CHAID, CART, KNN, regresión múltiple, ANN (MLP y RBF), boosted trees; CART para diagnóstico	Primera aplicación declarada de Random Forest a valoración masiva; usa segmentación para detectar dónde el modelo subestima o sobreestima. Resultado: Random Forest superó a todos los métodos comparados (sin cifras leídas).	Solo resumen	RQ1, RQ3
E07	Park y Bae (2015)	5.359 casas adosadas (MLS), Fairfax County, Virginia, EE. UU.	C4.5, RIPPER, Naïve Bayes, AdaBoost (clasificación)	Problema planteado como clasificación del precio, no como regresión. Resultado: RIPPER supera consistentemente a los demás por exactitud (sin cifras leídas).	Solo resumen	RQ1, RQ3
E08	Kok et al. (2017)	EE. UU., activos multifamiliares; n NR	AVM basado en aprendizaje automático; algoritmos NR	Un AVM con ML alcanza una exactitud comparable a la del avalúo manual. Resultado: Error absoluto cercano al 9 %, comparable con la exactitud de los avalúos tradicionales.	Solo resumen	RQ1
E09	Mullainathan y Spiess (2017)	No reportado en lo leído	No reportado en lo leído	El ML resuelve problemas de predicción, no de estimación de parámetros (según T09).	Solo resumen	RQ1, RQ3
E10	Čeh et al. (2018)	Liubliana (Eslovenia): 7.407 transacciones de apartamentos, 2008–2013; variables estructurales, ambientales y de vecindario (GIS)	Random Forest vs regresión múltiple hedónica	RF supera al hedónico en este mercado. Resultado: Random Forest superó sustancialmente a la regresión en todas las métricas (sin cifras leídas).	Solo resumen	RQ1, RQ3
E11	Dimopoulos y Bakas (2019)	Nicosia (Chipre), unidades residenciales; n y período NR	Algoritmos de ML/IA (no enumerados en el resumen) con análisis de sensibilidad	Propone ML para mejorar la exactitud y análisis de sensibilidad para dar transparencia a los AVM.	Solo resumen	RQ4

ID	Estudio	País y datos (n)	Modelos	Hallazgo y resultado verificable	Nivel	RQ
E12	Valier (2020)	Revisión sistemática (Scopus hasta jul. 2019): 381 resultados, 40 artículos comparables, ampliada con citas	Revisión: regresión vs redes neuronales, SVM, kNN y otros	El ML predice mejor pero es menos interpretable; los enfoques econométricos ofrecen mejor inferencia. Resultado: ML superó a la regresión en 57 comparaciones y la regresión a ML en 13; redes neuronales 37 vs 21, SVM 21 vs 5, kNN 5 vs 12; ningún algoritmo domina siempre.	Solo resumen	RQ1
E13	Truong et al. (2020)	China; ciudad NO confirmada en la fuente primaria (una fuente secundaria sugiere el dataset "Housing Price in Beijing"); n NR	Métodos de ML convencionales y avanzados con regresión; lista RF/XGBoost/LightGBM/stacking de T09 no verificada	Explora cómo influyen las variables en la predicción. La conclusión de sobreajuste de RF (T09) no se verificó.	Solo resumen	RQ1, RQ3
E14	Ho et al. (2021)	Hong Kong: ≈40.000 transacciones durante más de 18 años	SVM, Random Forest, Gradient Boosting Machine	RF y GBM predicen mejor; SVM es más rápido. Resultado: RF y GBM superan a SVM en las tres métricas (sin cifras leídas).	Solo resumen	RQ1, RQ3
E15	Rico-Juan y Taltavull de La Paz (2021)	El título confirma Alicante (España), precios de oferta	NR; el título indica ML con explicabilidad vs hedónico espacial	No verificado. Resultado: No verificado (el error < 2 % de T09 no se leyó).	Solo metadatos	RQ1, RQ4
E16	Steurer et al. (2021)	Resumen: aplicación empírica con cinco modelos AVM; dataset, país y n NR	Cinco modelos AVM comunes (no nombrados en el resumen)	Clasifica 48 métricas en 7 grupos según el aspecto de la distribución del error y propone una lista corta de 7. Resultado: La elección de la métrica puede cambiar la elección del modelo.	Solo resumen	RQ3
E17	Yalpır et al. (2021)	Turquía: encuesta a expertos y ciudadanos en Ankara, Konya y Kayseri; tres regiones de Konya para implementación	Regresión múltiple para validar las variables seleccionadas (no es ML)	Aplica técnicas de selección de variables y validación para valoración masiva. Resultado: Cifras no accesibles; no se extrajeron.	Solo resumen	RQ2, RQ3
E18	Mora-Garcia et al. (2022)	Alicante (España): microdatos georreferenciados antes y después de la pandemia, más catastro e indicadores socioeconómicos	Gradient Boosting, XGBoost, LightGBM (boosting); Random Forest y Extra-Trees (bagging); regresión lineal como referencia	El boosting generaliza mejor que el bagging en este estudio (según el resumen). Resultado: ML supera a los modelos lineales; el boosting rinde mejor y sobreajusta menos; el bagging muestra sobreajuste. Los $R^2 \approx 0{,}91$ y ≈ 0,90 de T09 no se verificaron.	Solo resumen	RQ1, RQ3
E19	Gao et al. (2022)	El título confirma Gran Sídney (Australia), áreas estadísticas	NR; el título menciona algoritmos de ML	No verificado. Resultado: No verificado (la superioridad de GB y RF sobre el hedónico de T09 no se leyó).	Solo metadatos	RQ1
E20	Stang et al. (2022)	Alemania: 1.212.546 viviendas, 2014–2020, 327 distritos NUTS-3; tasaciones de peritos de un grupo bancario	Comparables automatizados (EXF), OLS con selección hacia atrás, GAM (splines penalizados), XGBoost	XGBoost es el más exacto, pero OLS y GAM quedan cerca y a veces ganan en zonas rurales con pocos datos. Resultado: XGBoost (2020): MAPE 0,1465, R^2 0,8995. GAM: MAPE 0,1646, R^2 0,8664. OLS: MAPE 0,1736, R^2 0,8654. EXF: MAPE 0,2130, R^2 0,7735. XGBoost fue el mejor en el 79,2 % de los distritos.	Texto completo	RQ1, RQ3
E21	Bilgilioğlu y Yılmaz (2023)	1.982 datos de precedentes, 68 variables (Turquía inferido de la afiliación)	ANN, SVM, CHAID, CART y Random Forest	Compara cinco técnicas de ML para valoración masiva. Resultado: Cifras no accesibles; no se extrajeron.	Solo resumen	RQ1, RQ2

ID	Estudio	País y datos (n)	Modelos	Hallazgo y resultado verificable	Nivel	RQ
E22	Kim y Hong (2024)	Isla de Jeju (Corea del Sur), 2012–2021; el n = 63.306 de T09 no se leyó	Ensamble apilado (stacking) con meta-modelo ridge; algoritmos base NR	El stacking mejora a los modelos individuales. Resultado: El ensamble supera a los algoritmos individuales con menores errores (sin cifras leídas).	Solo resumen	RQ1, RQ3
E23	Deng y Zhang (2025)	Hong Kong; n y período NR	Ensamble de tres niveles + IA explicable (XAI); método de XAI no leído	La mayoría de atributos tienen relación no lineal con el precio; la edad del inmueble y las coordenadas son lo más influyente; hay efectos umbral en la densidad edificada. Resultado: Ensamble de tres niveles propuesto para mejorar la exactitud (sin cifras).	Solo resumen	RQ1, RQ4
E24	Pérez-Rave et al. (2020)	Colombia: 15.177 inmuebles (apartamentos)	Regresión lineal, árboles de regresión, Random Forest, bagging	Los ensambles superan a los modelos simples; atributos de texto se relacionan con el precio. Resultado: Random Forest y bagging tienen mayor poder predictivo (sin cifras leídas).	Solo resumen	RQ1, RQ2
E25	Rosso-Mateus et al. (2022)	Colombia: Fusagasugá, Manizales y Villavicencio; 2.397 anuncios de Fincaraiz (web scraping)	Regresión lineal, Ridge, Random Forest, Gradient Boosting	Metodología de dos etapas (scraping + ML) con fuentes alternativas. Resultado: MAPE ≈ 0,34–0,35 para RF y Ridge, diferencia mínima; el orden NO está confirmado (el extracto leído da RF 0,35 y Ridge 0,34, lo contrario de T09).	Solo resumen	RQ1, RQ2
E26	Grinsztajn et al. (2022)	45 datasets tabulares (OpenML), no específicos de vivienda; entrenamiento truncado a 10.000 muestras	Random Forest, XGBoost, GradientBoosting vs MLP, ResNet, FT-Transformer, SAINT	Los modelos de árboles superan a las redes profundas en datos tabulares típicos. Resultado: Los árboles siguen siendo el estado del arte en datos de tamaño medio (~10.000 muestras), incluso sin contar su velocidad (sin cifras extraídas).	Texto completo	RQ1

Tabla 7. Preprocesamiento, validación y métricas

ID	Preprocesamiento	Validación	Métricas
E01	No reportado en lo leído	No reportado en lo leído	No reportado en lo leído
E02	No reportado en lo leído	NR; el resumen menciona intervalos de predicción	No reportado en lo leído
E03	No reportado en lo leído	No reportado en lo leído	No reportado en lo leído
E04	No reportado en lo leído	Comparación de predicciones (detalle no leído)	No reportado en lo leído
E05	No reportado en lo leído	No reportado en lo leído	No reportado en lo leído
E06	No reportado en lo leído	No reportado en lo leído	No reportado en lo leído
E07	No reportado en lo leído	No reportado en lo leído	Exactitud de clasificación
E08	NR (solo se menciona información de ubicación hiperlocal)	No reportado en lo leído	Error absoluto del 9 % (sin precisar la métrica)
E09	No reportado en lo leído	No reportado en lo leído	No reportado en lo leído
E10	No reportado en lo leído	No reportado en lo leído	El resumen dice "todas las métricas"; no las enumera
E11	No reportado en lo leído	No reportado en lo leído	No reportado en lo leído
E12	No reportado en lo leído	No reportado en lo leído	Conteo de victorias frente a la regresión
E13	No reportado en lo leído	No reportado en lo leído	No reportado en lo leído
E14	No reportado en lo leído	No reportado en lo leído	MSE, RMSE, MAPE
E15	No reportado en lo leído	No reportado en lo leído	No reportado en lo leído

ID	Preprocesamiento	Validación	Métricas
E16	No reportado en lo leído	El resumen indica consenso en usar validación cruzada para selección de modelos	48 métricas en 7 grupos; lista corta de 7
E17	Selección de variables: análisis de frecuencia (FRA), PCA, análisis factorial y AHP	Validación en condiciones reales de mercado en tres regiones de Konya	No reportado en lo leído
E18	Preparación de datos, ingeniería de variables y optimización de hiperparámetros (resumen)	NR; se mencionan fases de evaluación y selección	No reportado en lo leído
E19	No reportado en lo leído	No reportado en lo leído	No reportado en lo leído
E20	Limpieza de atípicos, errores y faltantes; georreferenciación; 36 variables independientes	Ventana expansiva: entrenamiento 2014–2019, prueba en los cuatro trimestres de 2020, reentrenando cada trimestre	MAPE, MdAPE, PE(10), PE(20), R^2
E21	No reportado en lo leído	Partición entrenamiento/prueba (proporción NR)	Curva ROC y otros métodos estadísticos (detalle NR)
E22	No reportado en lo leído	No reportado en lo leído	Varias métricas (no especificadas)
E23	No reportado en lo leído	No reportado en lo leído	No reportado en lo leído
E24	Atributos derivados de texto (detalle NR)	Pruebas de estabilidad de atributos ante cambios de muestra; partición NR	No reportado en lo leído
E25	Web scraping y limpieza automatizada (CRISP-DM)	No reportado en lo leído	MAPE
E26	Eliminación de columnas y filas con faltantes; categóricas codificadas; transformaciones	Búsqueda aleatoria de hiperparámetros con presupuestos crecientes; mejor modelo según conjunto de validación	Exactitud (clasificación) y R^2 (regresión), normalizados

Tabla 8. Verificación de identificadores y observaciones sobre los metadatos de T09

ID	DOI o URL (T09)	Fuente consultada	Observaciones
E01	https://doi.org/10.1086/260169	EconPapers / RePEc (cita)	Metadatos coinciden. DOI no abierto en el editor.
E02	https://doi.org/10.1002/(SICI)1099-1255(199611)11:6<633::AID-JAE414>3.0.CO;2-T	IDEAS / RePEc	Metadatos coinciden.
E03	https://doi.org/10.1002/jae.929	RePEc (vía buscador)	Metadatos coinciden. Fuente secundaria.
E04	https://doi.org/10.1002/jae.1186	EconPapers / RePEc	Metadatos coinciden.
E05	https://www.sciencedirect.com/science/article/abs/pii/S0957417408000596	Buscador (datalearner, researchr)	Metadatos coinciden; ScienceDirect no abierto.
E06	https://www.sciencedirect.com/science/article/abs/pii/S0957417411011894	EconPapers (preprint MPRA)	Metadatos coinciden.
E07	https://doi.org/10.1016/j.eswa.2015.03.005	Buscador; DOI no abierto	Metadatos coinciden.
E08	https://cris.maastrichtuniversity.nl/en/publications/big-data-in-real-estate-from-manual-appraisal-to-automated-valuat/	Maastricht CRIS + Crossref	DOI según la fuente: 10.3905/jpm.2017.43.6.202. La fuente da "Carmen Martínez-Barbosa" (sin inicial intermedia).
E09	https://doi.org/10.1257/jep.31.2.87	Crossref + AEA	Metadatos coinciden. Hallazgo tomado de T09, no reverificado.
E10	https://doi.org/10.3390/ijgi7050168	Crossref	Metadatos coinciden.
E11	https://doi.org/10.3390/rs11243047	Crossref + OpenAlex	Metadatos coinciden.
E12	https://doi.org/10.1108/JPIF-12-2019-0157	Emerald	Metadatos coinciden; el autor es Agostino Valier. El resumen habla de 40 artículos; el conteo 53 informado por la lectura automática no coincide y no se usa.
E13	https://www.sciencedirect.com/science/article/pii/S1877050920316318	Crossref + OpenAlex	Metadatos coinciden. Abrir manualmente el PDF para confirmar ciudad, modelos y resultados.

ID	DOI o URL (T09)	Fuente consultada	Observaciones
E14	https://doi.org/10.1080/09599916.2020.1832558	PolyU + Crossref/OpenAlex	Año: 2020 en línea (Crossref) y 2021 en volumen (RePEc); T09 usa 2021.
E15	https://doi.org/10.1016/j.eswa.2021.114590	Semantic Scholar (título y año)	Autores, volumen y artículo no verificados (Crossref devolvió 429).
E16	https://doi.org/10.1080/09599916.2020.1858937	Crossref	Metadatos coinciden.
E17	https://doi.org/10.1016/j.landusepol.2021.105539	Crossref	Metadatos coinciden.
E18	https://www.mdpi.com/2073-445X/11/11/2100	Crossref + Semantic Scholar	DOI según Crossref: 10.3390/land11112100. El estudio es de Alicante, no de España en general.
E19	https://doi.org/10.1016/j.landusepol.2022.106409	Crossref (metadatos)	Metadatos coinciden.
E20	https://doi.org/10.1365/s41056-022-00063-1	PMC (acceso abierto)	Vol. 9, no. 2, pp. 81–108 no verificados (PMC muestra la versión en línea, pp. 1–28).
E21	https://doi.org/10.1080/00396265.2021.1996799	Crossref + Semantic Scholar	Publicado en línea en 2021 y en papel en 2023 (T09 cita 2023).
E22	https://www.mdpi.com/2073-445X/13/9/1436	Crossref	DOI según Crossref: 10.3390/land13091436.
E23	https://doi.org/10.1007/s00168-025-01365-7	Crossref	Cita según Crossref: vol. 74, no. 1, art. 32 (2025). Las pp. 1–28 de T09 no se confirmaron.
E24	https://doi.org/10.15446/dyna.v87n212.80202	Revista DYNA	Metadatos coinciden.
E25	https://doi.org/10.14483/23448393.17952	Revista Ingeniería (U. Distrital)	Discrepancia con T09 en el orden de RF y Ridge: revisar el texto original.
E26	https://papers.nips.cc/paper_files/paper/2022/file/0378c7692da36807bdec87ab043cdadc-Paper-Datasets_and_Benchmarks.pdf	PDF de NeurIPS + arXiv	El PDF de NeurIPS trae "typical" en el título; arXiv no.

4. Síntesis de hallazgos

4.1 Observaciones de la búsqueda

- **Tendencia dominante:** los ensambles de árboles (Random Forest, *gradient boosting*, XGBoost, *stacking*) logran la mayor exactitud predictiva, tanto frente al modelo hedónico (E06, E10, E12, E19, E20) como frente a otros algoritmos de ML (E13, E14, E18, E22, E24).
- **Contrapeso:** sobre **nuestro mismo dataset de Windsor**, la literatura econométrica muestra que una especificación paramétrica bien elegida es competitiva (E02–E04). Esto justifica usar el modelo hedónico como línea base fuerte y comparar con pruebas estadísticas.
- **Datos tabulares de tamaño pequeño o medio:** los modelos de árboles siguen siendo el estado del arte (E26). Esto respalda priorizar ensambles y modelos regularizados sobre redes profundas.
- **Métricas:** no hay una métrica única. Conviene reportar varias (RMSE, MAE, MAPE, R^2) según el propósito (E16).
- **Interpretabilidad:** es una brecha reconocida de los AVM. SHAP y el análisis de sensibilidad son las herramientas más usadas (E11, E15, E23).
- **Contexto local:** en Colombia, los estudios encontrados muestran la misma ventaja de los ensambles, con Ridge muy cerca (E24, E25).

4.2 Síntesis por pregunta de revisión

Las afirmaciones citan el número de referencia de cada estudio y respetan el nivel de verificación de la tabla 6. E13, E15 y E19 no se usan como evidencia.

RQ1 · Modelos de regresión y de aprendizaje automático

- Los resúmenes verificados reportan ventaja de los ensambles de árboles sobre la regresión: Random Forest supera a la regresión múltiple en Liubliana [10], a los demás métodos comparados en [6] y, con Random Forest y bagging, a los modelos simples en Colombia [24]; XGBoost es el más exacto en el estudio alemán leído completo [20]; el apilamiento supera a los modelos individuales [22] y la revisión de [12] cuenta 57 comparaciones favorables al ML frente a 13 favorables a la regresión.
- La ventaja no es uniforme. En [20], GAM (R^2 0,8664) y OLS (R^2 0,8654) quedan cerca de XGBoost (R^2 0,8995) y a veces ganan en zonas rurales con pocos datos; en [12] ningún algoritmo domina siempre; en [25] Ridge y Random Forest quedan casi empatados en MAPE (≈ 0,34–0,35, con el orden sin confirmar); y sobre los datos canadienses de referencia, [4] indica que una especificación paramétrica bien elegida no tiene por qué rechazarse.
- En datos tabulares de tamaño medio los árboles superan a las redes profundas [26], y entre ensambles el boosting generaliza mejor que el bagging en [18]. Esto respalda comparar regresión hedónica, modelos regularizados y ensambles, y no redes profundas, con 545 viviendas.
- Límite: 21 de los 26 estudios se verificaron solo por resumen, sin cifras; [15] y [19] solo por metadatos, y [13] no confirmó ni su ciudad. La comparación formal con la literatura se hará en el artículo final.

RQ2 · Estrategias de preprocesamiento

- El preprocesamiento se reporta poco en lo leído. Lo verificado incluye limpieza de atípicos, errores y faltantes con georreferenciación y 36 variables [20]; eliminación de faltantes, codificación de categóricas y truncamiento a 10.000 muestras [26]; selección de variables con análisis de frecuencia, PCA, análisis factorial y AHP [17]; atributos derivados de texto [24]; y raspado web con limpieza automatizada [25].
- En los textos accedidos no aparece una comparación sistemática de varias estrategias de preprocesamiento sobre los mismos datos y modelos. Esto no prueba que no exista: depende del acceso al texto completo.
- Para el proyecto, las tres estrategias de preprocesamiento (P1–P3, que define T11) y la comparación P1 vs P2 con log(precio) (H2) se plantean como decisión de diseño, no como práctica ya establecida en la literatura revisada.

RQ3 · Validación y métricas de evaluación

- Los esquemas de validación verificados son pocos: ventana expansiva con prueba temporal en 2020 [20] y búsqueda aleatoria de hiperparámetros con selección en un conjunto de validación [26]; [16] indica consenso en el uso de validación cruzada para seleccionar modelos y [24] evalúa la estabilidad de atributos ante cambios de muestra. Para el resto, el resumen no describe la validación.
- Las métricas varían: RMSE, MSE y MAPE [14]; MAPE, MdAPE, PE(10), PE(20) y R^2 [20]; MAPE [25]; exactitud [7]; curva ROC [21]. [16] clasifica 48 métricas en siete grupos y advierte que la métrica elegida puede cambiar el modelo ganador.
- El proyecto reportará RMSE, MAE, MAPE y R^2, con validación cruzada repetida y anidada sobre la partición de entrenamiento (T04, H1). La prueba t corregida es una decisión metodológica del proyecto; no se verificó que los estudios revisados la usen.

RQ4 · Interpretabilidad

- La interpretabilidad aparece como contrapeso del ML: [12] resume que el ML predice mejor pero es menos interpretable, y que los enfoques econométricos ofrecen mejor inferencia. Para [15], el título anuncia un contraste entre ML explicable e hedónico espacial, pero solo se verificaron sus metadatos.
- Las técnicas verificadas son el análisis de sensibilidad [11], la IA explicable en un ensamble [23] (el método concreto no se leyó) y el diagnóstico por segmentos con CART [6]. En [23], la edad del inmueble y las coordenadas son los atributos más influyentes y la mayoría de relaciones es no lineal.
- Ningún resumen verificado nombra SHAP de forma explícita; la afirmación de T09 de que SHAP es de las herramientas más usadas queda sin verificar y se contrastará con el texto completo.

5. Brechas y aporte del proyecto

Brechas respecto de lo leído que justifican la propuesta: comparación rigurosa entre aprendizaje automático y modelo hedónico sobre el dataset de Windsor, con validación cruzada repetida y anidada, pruebas estadísticas, análisis de complejidad e interpretabilidad.

- Comparación sobre el mismo dataset: los estudios econométricos sobre los datos de referencia (T09 los ubica en Windsor) comparan enfoques paramétricos y no paramétricos [2]–[4], y en lo leído no aparecen ensambles de árboles. El proyecto compara regresión hedónica, modelos regularizados y ensambles sobre esos mismos datos.
- Reporte de validación y preprocesamiento: en los textos accedidos estos aspectos aparecen poco o nada (RQ2 y RQ3). El proyecto los documenta de forma explícita: tres preprocesamientos, validación cruzada repetida y anidada sobre la partición sellada, y pruebas estadísticas.
- Costo y transparencia: [12] y [20] muestran que el ML mejora la exactitud con un costo en interpretabilidad y datos. El proyecto incorpora análisis de complejidad e interpretabilidad en la comparación.
- Tamaño pequeño: entre los estudios con n verificado, el menor es de 2.397 anuncios [25]; el proyecto trabaja con 545 viviendas, por lo que sus conclusiones no se generalizan a otros mercados.

Estas brechas se formulan a partir de lo leído (21 resúmenes, 2 textos completos y 3 solo metadatos). No se afirma novedad: se confirmará con las cadenas replicadas en Scopus o Web of Science para el artículo final.

6. Limitaciones

- **Alcance de la búsqueda:** las bases no se consultaron directamente; el motor devuelve los resultados más relevantes de cada dominio, no el universo completo. Para el artículo final se replicarán las cadenas booleanas en Scopus o Web of Science con el acceso de la biblioteca de la UAO, y se actualizarán los conteos.
- **Reportes no recuperados (19 en bases de datos y 1 por citas):** se intentarán recuperar con el acceso institucional y, si cumplen los criterios, se incorporarán a la revisión.
- **Evaluación por resumen:** la elegibilidad se decidió con el resumen y los metadatos. Si al leer el texto completo un estudio no cumple los criterios, se excluye y se actualizan los conteos.
- **Verificación de T10:** de los 26 estudios, 2 se leyeron completos, 21 solo en resumen y 3 solo en metadatos. Las páginas de ScienceDirect, MDPI, Taylor & Francis, Wiley y Springer bloquearon el acceso al texto completo. Los campos sin dato dicen "n. r.".
- **Hallazgos de T09 sin confirmar:** el orden de Random Forest y Ridge en [25], los R^2 de [18], el error < 2 % de [15], la ventaja de GB y RF en [19], la ciudad de [13] y la etiqueta "ML vs hedónico" de [21].
- **Referencias:** no se modificaron las de T09; las diferencias de DOI, volumen y páginas están en la tabla 8 para decidir su corrección.

Referencias

[1] S. Rosen, "Hedonic prices and implicit markets: Product differentiation in pure competition," *Journal of Political Economy*, vol. 82, no. 1, pp. 34–55, 1974, doi: 10.1086/260169.

[2] P. M. Anglin and R. Gençay, "Semiparametric estimation of a hedonic price function," *Journal of Applied Econometrics*, vol. 11, no. 6, pp. 633–648, 1996, doi: 10.1002/(SICI)1099-1255(199611)11:6<633::AID-JAE414>3.0.CO;2-T.

[3] C. F. Parmeter, D. J. Henderson, and S. C. Kumbhakar, "Nonparametric estimation of a hedonic price function," *Journal of Applied Econometrics*, vol. 22, no. 3, pp. 695–699, 2007, doi: 10.1002/jae.929.

[4] H. Haupt, J. Schnurbus, and R. Tschernig, "On nonparametric estimation of a hedonic price function," *Journal of Applied Econometrics*, vol. 25, no. 5, pp. 894–901, 2010, doi: 10.1002/jae.1186.

[5] H. Selim, "Determinants of house prices in Turkey: Hedonic regression versus artificial neural network," *Expert Systems with Applications*, vol. 36, no. 2, pp. 2843–2852, 2009, [Online]. Available: https://www.sciencedirect.com/science/article/abs/pii/S0957417408000596.

[6] E. A. Antipov and E. B. Pokryshevskaya, "Mass appraisal of residential apartments: An application of Random forest for valuation and a CART-based approach for model diagnostics," *Expert Systems with Applications*, vol. 39, no. 2, pp. 1772–1778, 2012, [Online]. Available: https://www.sciencedirect.com/science/article/abs/pii/S0957417411011894.

[7] B. Park and J. K. Bae, "Using machine learning algorithms for housing price prediction: The case of Fairfax County, Virginia housing data," *Expert Systems with Applications*, vol. 42, no. 6, pp. 2928–2934, 2015, doi: 10.1016/j.eswa.2015.03.005.

[8] N. Kok, E.-L. Koponen, and C. A. Martínez-Barbosa, "Big data in real estate? From manual appraisal to automated valuation," *Journal of Portfolio Management*, vol. 43, no. 6, pp. 202–211, 2017, [Online]. Available: https://cris.maastrichtuniversity.nl/en/publications/big-data-in-real-estate-from-manual-appraisal-to-automated-valuat/.

[9] S. Mullainathan and J. Spiess, "Machine learning: An applied econometric approach," *Journal of Economic Perspectives*, vol. 31, no. 2, pp. 87–106, 2017, doi: 10.1257/jep.31.2.87.

[10] M. Čeh, M. Kilibarda, A. Lisec, and B. Bajat, "Estimating the performance of random forest versus multiple regression for predicting prices of the apartments," *ISPRS International Journal of Geo-Information*, vol. 7, no. 5, art. 168, 2018, doi: 10.3390/ijgi7050168.

[11] T. Dimopoulos and N. P. Bakas, "Sensitivity analysis of machine learning models for the mass appraisal of real estate. Case study of residential units in Nicosia, Cyprus," *Remote Sensing*, vol. 11, no. 24, art. 3047, 2019, doi: 10.3390/rs11243047.

[12] A. Valier, "Who performs better? AVMs vs hedonic models," *Journal of Property Investment & Finance*, vol. 38, no. 3, pp. 213–225, 2020, doi: 10.1108/JPIF-12-2019-0157.

[13] Q. Truong, M. Nguyen, H. Dang, and B. Mei, "Housing price prediction via improved machine learning techniques," *Procedia Computer Science*, vol. 174, pp. 433–442, 2020, [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1877050920316318.

[14] W. K. O. Ho, B.-S. Tang, and S. W. Wong, "Predicting property prices with machine learning algorithms," *Journal of Property Research*, vol. 38, no. 1, pp. 48–70, 2021, doi: 10.1080/09599916.2020.1832558.

[15] J. R. Rico-Juan and P. Taltavull de La Paz, "Machine learning with explainability or spatial hedonics tools? An analysis of the asking prices in the housing market in Alicante, Spain," *Expert Systems with Applications*, vol. 171, art. 114590, 2021, doi: 10.1016/j.eswa.2021.114590.

[16] M. Steurer, R. J. Hill, and N. Pfeifer, "Metrics for evaluating the performance of machine learning based automated valuation models," *Journal of Property Research*, vol. 38, no. 2, pp. 99–129, 2021, doi: 10.1080/09599916.2020.1858937.

[17] Ş. Yalpır, S. Şişman, A. U. Akar, and F. B. Ünel, "Feature selection applications and model validation for mass real estate valuation systems," *Land Use Policy*, vol. 108, art. 105539, 2021, doi: 10.1016/j.landusepol.2021.105539.

[18] R.-T. Mora-Garcia, M.-F. Cespedes-Lopez, and V. R. Perez-Sanchez, "Housing price prediction using machine learning algorithms in COVID-19 times," *Land*, vol. 11, no. 11, art. 2100, 2022, [Online]. Available: https://www.mdpi.com/2073-445X/11/11/2100.

[19] Q. Gao, V. Shi, C. Pettit, and H. Han, "Property valuation using machine learning algorithms on statistical areas in Greater Sydney, Australia," *Land Use Policy*, vol. 123, art. 106409, 2022, doi: 10.1016/j.landusepol.2022.106409.

[20] M. Stang, B. Krämer, C. Nagl, and W. Schäfers, "From human business to machine learning—methods for automating real estate appraisals and their practical implications," *Zeitschrift für Immobilienökonomie*, vol. 9, no. 2, pp. 81–108, 2022, doi: 10.1365/s41056-022-00063-1.

[21] S. S. Bilgilioğlu and H. M. Yılmaz, "Comparison of different machine learning models for mass appraisal of real estate," *Survey Review*, vol. 55, no. 388, pp. 32–43, 2023, doi: 10.1080/00396265.2021.1996799.

[22] W. Kim and J. Hong, "Stacked ensemble model for the automatic valuation of residential properties in South Korea: A case study on Jeju Island," *Land*, vol. 13, no. 9, art. 1436, 2024, [Online]. Available: https://www.mdpi.com/2073-445X/13/9/1436.

[23] L. Deng and X. Zhang, "Boosting the accuracy of property valuation with ensemble learning and explainable artificial intelligence: The case of Hong Kong," *The Annals of Regional Science*, vol. 74, no. 1, pp. 1–28, 2025, doi: 10.1007/s00168-025-01365-7.

[24] J. I. Pérez-Rave, F. González-Echavarría, and J. C. Correa-Morales, "Modeling of apartment prices in a Colombian context from a machine learning approach with stable-important attributes," *DYNA*, vol. 87, no. 212, pp. 63–72, 2020, doi: 10.15446/dyna.v87n212.80202.

[25] A. E. Rosso-Mateus, Y. M. Montilla-Montilla, and S. C. Garzón-Martínez, "Metodología para obtención y análisis de datos inmobiliarios usando fuentes alternativas: estudio de caso en tres ciudades intermedias de Colombia," *Ingeniería*, vol. 27, no. 3, art. e17952, 2022, doi: 10.14483/23448393.17952.

[26] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?," *Advances in Neural Information Processing Systems (NeurIPS 2022)*, Datasets and Benchmarks Track, 2022, [Online]. Available: https://papers.nips.cc/paper_files/paper/2022/file/0378c7692da36807bdec87ab043cdadc-Paper-Datasets_and_Benchmarks.pdf.

[27] M. J. Page et al., "The PRISMA 2020 statement: An updated guideline for reporting systematic reviews," *BMJ*, vol. 372, art. n71, 2021, doi: 10.1136/bmj.n71.